

Eczaneler İin Kullanıcı Tabanlı Müstahzar Öneri Sistemi

Mert akar

YÜKSEK LİSANS TEZİ

Bilgisayar Mühendislięi Anabilim Dalı

Haziran 2022

User-Based Preparation/Drug Recommendation System for Pharmacies

Mert Çakar

MASTER OF SCIENCE THESIS

Department of Computer Engineering

June 2022

Eczaneler İin Kullanıcı Tabanlı Müstahzar Öneri Sistemi

Mert akar

Eskişehir Osmangazi Üniversitesi
Fen Bilimleri Enstitüsü
Lisansüstü Yönetmeliğı Uyarınca
Bilgisayar Mühendisliğı Anabilim Dalı
Bilgisayar Yazılımı Bilim Dalında
YÜKSEK LİSANS TEZİ
Olarak Hazırlanmıştır

Danışman: Do. Dr. Kemal Özkan

June 2022

ONAY

Bilgisayar Mühendisliği Anabilim Dalı Yüksek Lisans öğrencisi Mert Çakar'ın YÜKSEK LİSANS tezi olarak hazırladığı “Eczaneler İçin Kullanıcı Tabanlı Müstahzar Öneri Sistemi” başlıklı bu çalışma, jürimizce lisansüstü yönetmeliğin ilgili maddeleri uyarınca değerlendirilerek oybirliği ile kabul edilmiştir.

Danışman : Doç. Dr. Kemal Özkan

İkinci Danışman : -

Yüksek Lisans Tez Savunma Jürisi:

Üye : Doç. Dr. Kemal Özkan

Üye : Dr. Öğr. Üyesi Uğur Gürel

Üye : Dr. Öğr. Üyesi Cahit Perkgöz

Fen Bilimleri Enstitüsü Yönetim Kurulu'nun tarih ve
..... sayılı kararıyla onaylanmıştır.

Prof. Dr. Hürriyet ERŞAHAN
Enstitü Müdürü

ETİK BEYAN

Eskişehir Osmangazi Üniversitesi Fen Bilimleri Enstitüsü tez yazım kılavuzuna göre, Doç. Dr. Kemal Özkan danışmanlığında hazırlamış olduğum “Eczaneler İçin Kullanıcı Tabanlı Müstahzar Öneri Sistemi” başlıklı Yüksek Lisans tezimin özgün bir çalışma olduğunu; tez çalışmamın tüm aşamalarında bilimsel etik ilke ve kurallara uygun davrandığımı; tezimde verdiğim bilgileri, verileri akademik ve bilimsel etik ilke ve kurallara uygun olarak elde ettiğimi; tez çalışmamda yararlandığım eserlerin tümüne atıf yaptığımı ve kaynak gösterdiğimi ve bilgi, belge ve sonuçları bilimsel etik ve kurallara göre sunduğumu beyan ederim.

14/06/2022

Mert Çakar

ÖZET

Çevrim içi platform ve servislerin sayısının her gün daha da artması sebebiyle öneri sistemlerinin hayatımızdaki etkisi de giderek artmaktadır. Bu sistemlerin kullanıldığı en yaygın alanlar olarak e-ticaret siteleri, sosyal medya siteleri, müzik ve video platformları karşımıza çıksa da hemen hemen her sektör içerisinde kullanılabilmektedir. Sağlık alanında yapılan çalışmalar doktorların hastalarına doğru müstahzar ile doğru tedaviyi sunmasına yardım edecek şekilde ilerlemektedir. Hastalara tedavileri için doğru müstahzarın seçilmesi çok önemli bir konu olmakla birlikte bu müstahzarın hastalar ile buluşturulması da bir o kadar önemlidir. Bu çalışmada eczanelerde yer alan sistemlerin verimliliğini arttırarak eczacıların yükünü hafifletecek ve aynı zamanda hastaların bekleme süresini azaltarak memnuniyeti artıracak bir hibrit öneri sistemi geliştirilmiştir. Bu sistem geliştirilirken kullanıcı-ürün ilişkileri yanına ürün-ürün ilişkileri eklenerek LightGCN+ adı verilen yeni bir sistem önerilmiştir. Eczaneler için geliştirilen bu sistemin yanında gelecekteki çalışmalara katkıda bulunabilmek ve bu alandaki en iyi sonuçlara ulaşabilmek amacıyla canlı sistem verileri ile oluşturulmuş üç farklı veri seti de sunulmuştur. Kesinlik, duyarlılık ve F1 skor metrikleri için sonuçlar incelendiğinde sisteme eklenen ürün-ürün ilişkileri sonrasında öneri sisteminin daha başarılı sonuçlara ulaştığı ve ortalamaya bakıldığında performansın %12,85 oranında arttığı görülmektedir. Bunun yanında eğitim ve test süreleri incelendiğinde ise ortalama olarak %0,3 lük bir hızlanma söz konusudur.

Anahtar Kelimeler: Hibrit Öneri Sistemi, Grafik Evrişimsel Ağlar, Eczane Öneri Sistemi

SUMMARY

Since the number of online platforms and services is increasing day by day, the impact of recommendation systems on our lives is also increasing. Although e-commerce sites, social media sites, music and video platforms are the most common areas where these systems are used, they can be used in almost every area. Studies about the field of health are advancing to help doctors to find right treatment with the right preparation for their patients. Though choosing the right preparation for the treatment of patients is very important issue, it is equally important to bring preparation together with the patients. In this study, a hybrid recommendation system has been developed that will increase the efficiency of the systems in pharmacies so that pharmacists make easy their works and at the same time increase satisfaction by reducing the waiting time of the patient. While a new system which called LightGCN+ has been proposed by adding item-item relations next to user-item relations. In addition to this system which developed for pharmacies, three different datasets that created with live system data have been proposed to achieve the best results and contribute to future studies in this area. When the results examined for precision, recall and F1 score, it is seen that the recommendation system achieved more successful results after the item-item relations added to the system and the performance increased by 12,85% when looking at the average. In addition, when the training and test durations are examined, there is an average of 0,3% acceleration.

Keywords: Hybrid Recommendation System, Graph Convolutional Network, Pharmacy Recommendation System

TEŞEKKÜR

Tez sürecinde, yapılan araştırmalarda, karşılaştığım zorluklarda ve tezimin tamamlanmasında yol gösteren ve bana her zaman destek olan tez danışmanım Doç. Dr. Kemal ÖZKAN’a teşekkür ederim.

Tez çalışmam için veri setini oluşturmamda verdikleri destekten dolayı başta sayın Prof. Dr. Levent ÜSTÜNES olmak üzere RxMediaPharma’ya teşekkür ederim.

Tez çalışmalarımı tamamlayabilmem için bana destek olan ve yardımlarını hiçbir zaman esirgemeyen başta Yusuf KARTAL ve Furkan AVCI sonrasında Yiğit Can TÜRE ve Kaan AKDENİZ olmak üzere tüm AVKAR Yazılım ailesine teşekkür ederim.

Bugüne gelmemde en büyük emeğe sahip ve her zaman yanımda olan annem Semra ÇAKAR ve babam Hüseyin ÇAKAR’a teşekkür ederim.

Tez çalışmam sürecinde her zaman, her koşulda yanımda olan ve desteğini asla esirgemeyen sevgili eşim Gizem ÇAKAR’a teşekkürü bir borç bilirim.

İÇİNDEKİLER

Sayfa

ÖZET	vi
SUMMARY	vii
TEŞEKKÜR	viii
İÇİNDEKİLER	ix
ŞEKİLLER DİZİNİ	x
ÇİZELGELER DİZİNİ	xi
1. GİRİŞ VE AMAÇ	1
2. LİTERATÜR ARAŞTIRMASI	5
3. GENEL BİLGİLER	11
3.1. Öneri Sistemleri	11
3.1.1. İçerik tabanlı filtreleme (Content based filtering)	15
3.1.2. İş birliği tabanlı filtreleme (Collaborative filtering)	17
3.1.3. Hibrit sistemler (Hybrid systems)	18
3.2. Öneri Sistemlerinin Karşılaştığı Problemler	20
3.3. Yapay Sinir Ağları (Artificial Neural Network)	21
3.3.1. Derin Öğrenme (Deep Learning)	22
3.3.2. Evrişimsel Sinir Ağları (Convolutional Neural Network)	23
3.3.3. Grafik Evrişimsel Ağlar (Graph Convolutional Network - GCN)	24
3.3.3.1. Komşuluk Matrisi (Adjacency Matrix)	26
3.4. Öneri Sistemleri İçin Eğitim Sonuçlarının Değerlendirilmesi	29
4. MATERYAL VE YÖNTEM	33
4.1. Kullanılan Veri Seti	33
4.2. Kullanılan Metot	36
4.2.1. GCN	36
4.2.2. LightGCN	39
4.2.3. LightGCN+	41
5. BULGULAR VE TARTIŞMA	44
6. SONUÇ VE ÖNERİLER	49
KAYNAKLAR DİZİNİ	51

ŞEKİLLER DİZİNİ

<u>Sekil</u>	<u>Sayfa</u>
3.1. Amazon puanlama sistemi için örnek gösterim	12
3.2. Netflix kullanıcı ve ürün ilişkileri için örnek görselleştirme	13
3.3. Sosyal ağlar için örnek kullanıcı bağlantı gösterimi	14
3.4. Öneri Sistemi Yöntemleri	15
3.5. İçerik tabanlı filtreleme yapısı	16
3.6. İş birliği tabanlı filtreleme yapısı	17
3.7. Hibrit bir öneri sistemi yapısı	19
3.8. Örnek bir yapay sinir ağı yapısı	22
3.9. Örnek bir evrişimsel sinir ağı yapısı	24
3.10. Grafik evrişimsel ağ yapıları a) Düğüm sınıflandırma yapısı b) Bağlantı tahmin yapısı c) Grafik Gömme yapısı	25
3.11. Karşılıklı matrisinin görselleştirmesi	29
3.12. Kesinlik ve duyarlılık metrikleri	31
4.1. Veri seti için toplanana örnek müstahzar arama bilgileri	33
4.2. Veri seti oluşturulurken kullanıcılara göre gruplanan örnek müstahzar bilgileri	34
4.3. Veri seti içerisine eklenmek için toplanan ürün-ürün bilgileri	35
4.4. İkili grafik örnek gösterimi	38
4.5. Grafik evrişimsel sinir ağı mimarisinin örnek yapısı	49
4.6. Hafif grafik evrişimsel sinir ağı mimarisinin örnek yapısı	41
4.7. Ürün-ürün ilişkileini içeren temsili komşuluk matrisi gösterimi	42
5.1. Oluşturulmuş veri setleri üzerinde çalıştırılan LightGCN ve LightGCN+ modelleri için oluşan eğitim eğrileri a) Drug-Relation-90 veri seti, b) Drug-Relation-180 veri seti, c) Drug-Relation-270 veri seti	46
5.2. LightGCN ve LightGCN+ modellerinin oluşturulan veri setleri üzerindeki performansları a) LightGCN, b) LightGCN+	47

ÇİZELGELER DİZİNİ

<u>Cizelge</u>	<u>Sayfa</u>
3.1. Örnek bir karşıtlık matrisi	30
4.1. Oluşturulan veri setlerinin ayrıntıları	35
4.2. Veri setine eklenen eşdeğer (ürün-ürün) ilişkileri	36
5.1. Farklı katmanlarda LightGCN ve LightGCN+ performans karşılaştırması	44
5.2. Farklı katmanlarda LightGCN ve LightGCN+ F1 skor karşılaştırması	45
5.3. Farklı katmanlarda LightGCN ve LightGCN+ çalışma süreleri karşılaştırması	48

1. GİRİŞ VE AMAÇ

Günümüzde gelişen teknolojinin de etkisiyle internetin hayatımıza tamamen girmesi çevrim içi geçirdiğimiz sürenin ve etkileşimin artmasına neden olmuştur. Bununla birlikte artan veri miktarı sonucunda öneri sistemleri hayatımıza hızla girmiş ve önemli bir yer edinmiştir. En genel açıklamasıyla öneri sistemleri, diğer kullanıcı hareketleri ya da içerik benzerliklerinden yola çıkarak kullanıcıların aradıkları içerikleri bulmalarına yardım eden sistemlerdir (Park vd., 2012). Önemli kullanım alanları olarak çevrim içi alışveriş siteleri, sosyal medya uygulamaları, müzik ve video platformları karşımıza çıksa da kullanım alanları her geçen gün artmakta ve neredeyse her sektörde kendisine yer bulabilmektedir.

Öneri sistemlerinin en yaygın kullanımı e-ticaret siteleridir. Bunun sebebi ise öneri sistemleri sayesinde kullanıcı hız ve rahatlık kazanırken firmanın da satış şansının yükselmesi ile karşılıklı bir fayda sağlanmasıdır (Kurt, 2019). Benzer şekilde, video ve müzik platformları düşünüldüğünde de kullanıcının aradığı ve beğeneceği içeriklerin önerilmesi kullanıcının memnuniyetinin artmasına, dolayısıyla platformu kullanmaya devam etmesine böylece de firmanın kazanç sağlamasına sebep olacaktır. Örneklerde net şekilde belirtildiği gibi öneri sistemlerinin sağladığı karşılıklı fayda ilişkisi, gün geçtikçe kullanıldığı alanların genişlemesine ve yaygınlaşmasına yol açmaktadır.

Öneri sistemlerinin gelecekte sıklıkla kullanılacağı sektörlerden birisi de hiç kuşkusuz sağlık sektörüdür. Son yıllarda sağlık alanında yapılan öneri sistemi çalışmaları, doktorların hastalarına doğru müstahzarı¹ vermelerinde yardımcı olacak şekilde ilerlemektedir (Gong vd., 2021). Hastalık teşhisi ve hastalığa yönelik doğru tedavilerin hastalarla buluşması çok önemli çalışma alanlarıdır. Bunun yanında sağlık sektörünün çok önemli bir ayağı da hastaları müstahzarlar ile buluşturan eczanelerdir. Eczacılar yaptıkları iş ile insan sağlığına dokunurlar ve bu sebeple her zaman en doğru bilgiye en hızlı şekilde ulaşmaları gerekir.

¹ Müstahzar, bir üretici kuruluş tarafından standart bir formüle göre belirli bir şekle sokularak özel bir isim altında ambalajlanarak pazarlanan ürün anlamına gelmektedir.

Tüm bu bilgiler ışığında eczaneler ve eczacılar düşünüldüğünde daha hızlı, daha başarılı ve daha tutarlı öneriler ile verimliliğin artırılması gereken bir alan ortaya çıkmaktadır. Bu durumun aksine literatür incelendiğinde bu alanda gerçekleştirilen çalışmaların oldukça kısıtlı olduğu görülmektedir ve yeni çalışmaların yapılmasına uygun bir alan gün yüzüne çıkmaktadır.

Bu çalışma kapsamında eczanelerde kullanılan sistemlerdeki verimliliğin hızlı ve başarılı öneri sonuçları ile artırılması amaçlanmaktadır. Daha net bir ifade ile ortaya çıkartılan yeni sistemin hedef kitlesi insan hayatında önemli bir role sahip olan eczacılardır. Eczacılar doğru bilgiye ulaşarak hastalarını doğru tedaviler ile buluşturmak için çalışma sürelerinin büyük bir kısmını telefon, tablet, bilgisayar gibi teknolojik cihazların başında geçirmektedir. Doktorlar tarafından yönlendirilen ve reçeteleri ile gelen hastalarda bu süreç önemsiz olarak gözüксе de eczaneye gelen hastaların büyük bir kısmının hızlı çözümler aramaları nedeniyle doğrudan eczanelere geldiği bir gerçektir. Bu tip durumlarda eczacıların onları en hızlı şekilde, en doğru tedavi ile buluşturması önem kazanmaktadır. Doğru bilgiye en kısa yoldan ulaşmanın bu kadar hayati önem taşıdığı bir alanda yapılan bu çalışma sonucunda eczane sistemlerinin kalitesinin artması, bununla beraber eczacının cihaz başında geçirdiği sürenin azaltılarak veriminin artması hedeflenmiştir. Aynı zamanda müşteri olarak da tanımlayabileceğimiz hastaların tedavilerini bekleme süresini minimuma indirerek memnuniyeti maksimize etmek dolayısıyla karşılıklı bir fayda oluşması amaçlanmıştır.

Öneri sistemleri, önerileri oluşturma yöntemlerine göre farklı gruplara ayrılmaktadır. Bu gruplar içerik tabanlı filtreleme (Content Based Filtering), iş birliği tabanlı filtreleme (Collaborative filtering), demografik filtreleme (Demographic Filtering) ve hibrit sistemler (Hybrid Recommendations) olarak isimlendirilebilir (Narke ve Nasreen, 2020). Hibrit sistemlerin ortaya çıkmasının ve tercih edilmesinin en büyük sebebi iş birliği tabanlı ve içerik tabanlı yöntemlerin bir arada kullanılarak zayıflıklarının ortadan kaldırılması dolayısıyla daha başarılı sonuçlara ulaşılabilmesinin hedeflenmesidir (Danilova ve Ponomarev, 2017). Özellikle içerik tabanlı ve iş birliği tabanlı filtreleme yöntemleri düşünüldüğünde tek başına kullanıldıklarında öneri sonuçlarında bazı aksaklıklar yaşanabilmektedir. Örneğin, iş birliği tabanlı filtreleme yöntemleri için sisteme yeni eklenen ve henüz etkileşime girmeyen ürünün önerilmesi bir sorun olarak karşımıza çıkar. Benzer şekilde içerik tabanlı filtreleme yöntemlerinde ise kullanıcının geçmiş alışkanlıkları dışında

önerilerde bulunamamak sorun teşkil etmektedir. Bunun gibi durumların önüne geçmek için ise bu iki yöntemlerin birlikte kullanıldığı hibrit sistemler ortaya çıkmaktadır.

Öneri sistemlerinin oluşturulmasının önemli olduğu kadar oluşturulan öneri sistemlerinin değerlendirilerek kullanım alanına göre sisteme en uygun modelin seçilmesi de bir o kadar önemli bir konudur. En sık kullanılan değerlendirme metrikleri doğruluk, duyarlılık, kesinlik ve F1 skor olarak sıralanabilir. Değerlendirme için uygun metrikler seçilerek kullanılmadığında hatalı bir modelin seçilmesi ve dolayısıyla sistemden beklenen faydanın ve performansın sağlanamaması olasıdır.

Bu çalışmada, He vd. (2020) tarafından geliştirilen ve iş birliği tabanlı bir yöntem olan hafif grafik evrimsel ağ (Light Graph Convolutional Network - LightGCN)¹, içerik tabanlı filtreleme özellikleri yardımıyla genişletilerek hibrit bir sistem oluşturulmuştur. Daha net bir ifade ile LightGCN içerisinde kullanılan kullanıcı-ürün ilişkileri ürün-ürün ilişkileri ile genişletilerek yeni bir yöntem önerilmiştir. Eczacılar düşünülerek geliştirilen bu sistem düşünüldüğünde kullanıcı-kullanıcı ilişkilerini sistemin içerisine katmak olasılıklar dahilinde olmayacaktır ve ürün-ürün ilişkileri sistemin performansını arttırabilmek için çok önemli bir veriyi içinde barındırmaktadır. Geliştirilen bu yeni yöntem ile daha hızlı ve daha başarılı öneri sonuçlarına ulaşıldığı görülmüştür. Geliştirilen bu yeni yönteme ise LightGCN+² adı verilmiştir.

LightGCN+ geliştirilirken aynı zamanda eczanelerde kullanılan sistemlerden elde edilen veriler yardımı ile yeni bir veri seti oluşturularak çalışmalar bu veri seti üzerinde tamamlanmıştır. En başarılı ve tutarlı veri setini oluşturabilmek için toplanan veriler farklı değerler ile ön işleme sokulmuş ve sonucunda üç farklı veri seti elde edilmiştir. Öneri sistemi eğitim ve test işlemleri bu veri setleri üzerinde ayrı ayrı uygulanarak en başarılı ve tutarlı sonucu veren veri setine ulaşılmış böylece gelecek çalışmalar için de katkı sağlanması hedeflenmiştir.

¹ <https://github.com/kuandeng/LightGCN>

² <https://github.com/xChivalrouSx/LightGCN-plus>

Öneri sistemleri hakkında yapılan ve bu çalışma kapsamında incelenen geçmiş çalışmalara Bölüm 2’de yer verilmiştir. Bölüm 3’te öneri sistemleri, öneri sistemlerinin sınıflandırılması, bu sistemlerin karşılaştığı problemler ve öneri sistemleri geliştirilirken kullanılan derin öğrenme yöntemleri hakkında detaylı bilgi paylaşılmış ardından bu çalışmada kullanılan veri seti ve öneri yöntemi hakkındaki bilgiler Bölüm 4’te açıklanmıştır. Bölüm 5’te gerçekleştirilen çalışma sonucunda ulaşılan bulgular hakkında ayrıntılara yer verilmiş, bölüm 6’da yapılan çalışma ile ulaşılan sonuçlar değerlendirilmiş ve gelecekte yapılabilecek çalışmalar hakkında önerilere yer verilmiştir.

2. LİTERATÜR ARAŞTIRMASI

Literatürde öneri sistemleri ile ilgili birçok çalışma yer almaktadır. Bu bölümde literatürdeki çalışmalar arasında özellikle sağlık sektörü göz önünde bulundurularak hangi yöntemlerin öne çıktığı ve nasıl sonuçlar edinildiği incelenecektir.

Bobadilla vd. (2013) öneri sistemleri hakkında yaptıkları çalışmada özellikle iş birliğine dayalı sistemlerin nasıl çalıştığını inceleyerek geçmişten günümüze nasıl geliştiğine yer vermişlerdir. Soğuk başlangıç (cold start) probleminin ayrıntılarına değinmiş yaptıkları detaylı analizlerin ardından ise bu sistemlerin gelecekte hangi tür çalışmalar ile şekillendirilip geliştirilebileceğinden bahsetmişlerdir. Felfernig vd. (2014) çalışmalarında öneri sistemlerinde kullanılan temel yöntemler olan iş birliğine dayalı filtreleme, içeriğe dayalı filtreleme, bilgi tabanlı filtreleme ve hibrit sistemler hakkında ayrıntılı bilgiler vermişlerdir. Devamında ise, bu yöntemlerin nasıl kullanılması gerektiği hakkında ipuçları vererek çalışmalarını tamamlamışlardır.

Čano ve Morisio (2017) çeşitli sistemlerin birlikte kullanılması ile oluşan hibrit öneri sistemleri hakkında özellikle son on yıl içinde yapılan çalışmaları incelemiş, değerlendirmiş ve karşılaştırmışlardır. Tüm bu değerlendirme ve karşılaştırmalardan önce temel öneri sistemleri hakkında gerekli bilgileri paylaşmışlar ve nasıl bir arada kullanılarak verimin artırılabilirliğini açıklamışlardır. Soğuk başlangıç ve veri seyrekliğinin (data sparsity) bu konuda yer alan en büyük problem olduğunu belirterek bu iki problem için yaptıkları araştırmaları paylaşmışlardır. Zhang vd. (2019) günümüzde sistemler üzerinde bilgi yükünün ne kadar arttığından bahsetmiş ve öneri sistemlerinin bu yükün üstesinden gelme konusunda çok önemli bir işlevi olduğuna değinmişlerdir. Yaptıkları araştırmada özellikle öneri sistemleri içerisinde kullanılan derin öğrenme yöntemleri üzerinde durarak bu yöntemleri ayrıntıları ile açıklamış ve yapılan çalışmaları incelemişlerdir. Araştırmalarının sonunda ise gelecekte kullanılabilecek yeni bakış açılarına değinmişlerdir.

Narke ve Nasreen (2020) çalışmalarında öneri sistemleri için kullanılan teknikleri eksileri ve artıları ile derinlemesine incelemişlerdir. Soğuk başlangıç ve veri seyrekliği gibi sorunların hibrit sistemler aracılığı ile daha verimli çözümlere kavuştuğunu belirtmişlerdir.

Dwiputriane vd. (2022) yaptıkları çalışmada veri seyrekliğinin günümüzde öneri sistemleri için nasıl zorluklar oluşturduğundan bahsetmişlerdir. Çözüm olarak seçtikleri iki yöntem olan makine öğrenimi ve matris çarpanlara ayırma (Matrix Factorization) yöntemlerini MovieLens veri seti üzerinde uygulamış ve sonuçları karşılaştırmışlardır. Çalışmalarının sonunda ise grafik tabanlı sistemlerin (Graph Based Systems) gelecekte çok önemli bir yere sahip olacağını belirtmişlerdir.

Gras vd. (2016) gri koyun (grey sheep) olarak adlandırılan kullanıcıları belirlemek için bir teknik önermişlerdir. Gri koyun olarak adlandırılan kullanıcıları detayları ile açıkladıkları çalışmalarında bu durumun neden bir problem oluşturduğunu ve bu kullanıcıların nasıl belirlenerek sorunun çözülebileceği ile alakalı bilgiler paylaşmışlardır.

Derin öğrenme tabanlı makine öğrenimi yöntemleri hakkında önemli araştırmalar yapan Da'u ve Salim (2020) 2007 ve 2018 arasında yayınlanmış olan çalışmaları inceleyerek karşılaştırmışlardır. Bu konuda hazırlanmış ilk sistematik literatür incelemesine imza attıklarını belirtmiş aynı zamanda yayınları nasıl seçip inceledikleri hakkında da ayrıntılı bilgiler paylaşmışlardır. Derin öğrenme yöntemlerinin farklı veri setleri üzerinde nasıl performanslar sergilediklerini paylaşarak çalışmanın en büyük amacının gelecekteki araştırmacılara yön göstermek olduğunu belirtmişlerdir.

Welling ve Kipf (2017) çalışmaları sonucunda evrişimsel sinir ağlarının (Convolution Neural Networks) bir türü olan ve doğrudan grafik üzerinden çalışan bir yaklaşım önermişlerdir. Bu sistem ile grafik yapısını bir sinir ağı yardımı ile şifreledikten sonra eğitim işlemini gerçekleştirdiklerini ve modelin performansının oldukça başarılı olduğunu belirtmişlerdir. Wu vd. (2019) grafik evrişimsel ağların (Graph Convolutional Networks) ve türevlerinin ilgi kaynağı olduğundan bahsetmişlerdir. Bu yöntemlerin derin öğrenme yaklaşımlarından ilham aldığını ve bunun sonucunda barındırdığı karmaşıklık nedeni ile performansının yeterli kalmayabildiğine değinmişlerdir. Çalışmalarının sonucunda doğrusal olmayan matris işlemlerini kaldırdıkları ve basit grafik evrişim (Simple Graph Convolution) adını verdikleri yeni bir yöntemi önermişlerdir. Bu sistem üzerindeki sonuçları incelediklerinde eğitim zamanının önemli ölçüde düştüğünü gözlemişlerdir.

Wang vd. (2019) vektör gösterimlerinin modern öneri sistemlerinin temeli olduğunu belirttikleri çalışmalarında sinirsel grafik tabanlı iş birliği filtreleme (Neural Graph Collaborative Filtering) modeli oluşturmuşlardır. Üç farklı veri seti üzerinde ve farklı parametreler yardımıyla elde ettikleri çıktıları değerlendirmiş ve başarılı sonuçlar elde ettiklerini belirtmişlerdir. He vd. (2020) ise sinir grafik evrimsel filtreleme (Neural Graph Collaborative Filtering - NGCF) modeli üzerinde hantallığa sebep olan parçaları kaldırarak LightGCN adında bir model oluşturmuşlardır. Yeni oluşturdukları sistemin eskisine oranla hız ve öneri başarısı açısından daha performanslı olduğunu belirtmişlerdir.

Ubaid vd. (2021) rastgele algoritmaların öneri sistemleri üzerindeki etkisi hakkında yaptıkları çalışmalarında sadece rastgele bir algoritma kullanma yöntemini açıklamakla kalmayıp aynı zamanda bunun sistem üzerinde sağladığı avantajlarını da belirtmişlerdir. Ayrıca çalışmanın gelecekte yapılacak araştırmalarda öneri sistemlerinin gelişmesine yol göstereceği belirtilmiştir. İnceledikleri algoritmalar sırasıyla rastgele filtrelenmiş sınıflandırıcı (Randomizable Filtered Classifier), rastgele ağaç (Random Tree), rastgele orman (Random Forest), Monte Carlo algoritması (Monte Carlo Algorithm), Las Vegas algoritması (Las Vegas Algorithm) ve Atlantic City algoritması (Atlantic City Algorithm) yer almaktadır.

Shafiq vd. (2022) son iki yıl içerisinde hayatımızı çok büyük oranda etkileyen COVID-19'un ölüm oranlarını yapay sinir ağları ile hesaplayacak bir uygulama üzerinde çalışmışlardır. Yapay sinir ağlarına ek olarak çalışmalarında maksimum olasılık tahmini metodundan da yararlanmışlardır. Çalışma ardından ulaştıkları sonuçları değerlendirdiklerinde iki yöntem için de yüksek güvenilirliğe sahip modellerin ortaya çıktığını belirtmişlerdir. Ayrıca bu çalışma derin öğrenme yöntemlerinin günümüz gerçek yaşam problemlerini çözmede ne kadar etkili olduğunu da göstermiştir.

Grattarola (2021) iki parça olarak açıkladığı çalışmasının ilk aşamasında grafik sinir ağlarının öğrenim grafik temsilleri için üç yeni operatör sunmuştur. Bunların biri grafik evrimsel katmanı diğer ikisi ise havuzlama parçası içindir. İkinci aşama olarak ise grafik sinir ağlarının dinamik sistemlerdeki keskin kenar problemine odaklanarak üç ana katkıda bulunduğunu belirtmiştir. Bunlardan birincisi ortaya koyduğu otomatik kodlayıcı yapısı,

ikincisi yorumlanabilir olarak önerdiği yeni bir grafik sinir ağı modeli, sonuncusu ise grafik dizileri için öz bağımlı modeller hakkında görüşleridir.

Shchur vd. (2019) çalışmalarında grafik sinir ağları için yapılan değerlendirme stratejilerinin büyük eksiklikler içerdiğine değinmişlerdir. Aynı veri setinin sürekli olarak eğitim, test ve doğrulama olacak şekilde aynı parçalara ayrılmış şeklini kullanmanın adil bir karşılaştırmayı önlediğini belirterek erken durdurma kriterleri gibi birçok eğitim prosedürünün doğru sonuçlara ulaşılmasına ve adil karşılaştırmalara engel olduğunu belirtmişlerdir. Çalışmalarının ardından çıkan sonuçların gelecekteki çalışmalar için daha sağlam ve adil değerlendirme prosedürlerinin kullanılmasına teşvik edeceğini umduklarını dile getirmişlerdir.

Chen vd. (2020) grafik evrimsel ağlar ile ilgili yaptıkları çalışmalarında bu sistemlerin evrimsel toplama işlemi yapılan birden fazla katman içerdiğini ve aynı şekilde bu katmanlarda doğrusal olmayan aktivasyon işlemlerinin de gerçekleştiğini belirtmişlerdir. Bu tarz sistemlerde büyük bir kullanıcı-ürün etkileşim grafiği yer aldığına öğrenmenin zorluğuna değinmişlerdir. Önerdikleri sistem ile öncelikle doğrusal olmayan aktivasyon işlemlerinin kaldırılarak performansın artırıldığını ve hafif bir grafik evrimsel ağı elde edildiğini belirtmişlerdir. Ardından sistemlerinin doğrusal bir model kullandıkları için daha kolay bir şekilde eğitilebildiğini ayrıca büyük veri setleri için de oldukça ölçeklenebilir olduğunu söylemişlerdir. Son olarak önerdikleri sistemi iki farklı canlı veri seti üzerinde uyguladıklarında daha verimli ve etkin sonuçların ortaya çıktığını açıklamışlardır.

Tripathy vd. (2020) özellikle tek düğümlü makinelerin bellek sınırı olabileceğine değinerek bu tarz durumlarda yaşanabilecek en temel iki zorluğun iletişim maliyeti ve yük dengesi olduğunu söylemişlerdir. Çalışmalarında grafik sinir ağları için iletişim maliyetini en aza indirmeye odaklanmışlar kullandıkları algoritmalar yardımı ile yük dengesinin de otomatik olarak dağıtıldığından bahsetmişlerdir. Deneysel olarak gerçekleştirdikleri çalışmanın sonunda basit olarak düzenlenmiş bir varyant modelin bile hazır araçlar yardımı ile kullanıldığında ölçeklenebilir olabileceğini görmüşlerdir.

Zhang vd. (2015) yeni bir müstahzar öneri sistemi üzerine yaptıkları çalışmada e-ticaretin gelişmesi ile insanların çevrim içi müstahzar alım konusunda da eğilimlerinin

arttığını belirtmişlerdir. Bu tarz ortamlarda gerekli yardımı ve desteği sağlayacak sistemler olmadığını belirtmiş ve bu durumun çevrim içi müstahzar alımı konusunda en büyük problem olarak ortaya çıktığına değinmişlerdir. Oluşturdukları bulut destekli (cloud-assisted) öneri sistemi ile bu sorunu ortadan kaldırmayı amaçlayarak çalışmalarının sonucunda geçerli ve düzenli öneriler yapan bir sistem oluşturduklarını belirtmişlerdir. Hu vd. (2017) çalışmalarında içerisinde müstahzar öneri sistemi ve teşhis destek sistemi bulunan bir elektronik tıbbi kayıt sistemi üzerinde çalışmışlardır. Elektronik ortamda tutulan kayıtların kurumlar arasında bilgilerin aktarılmasını fazlasıyla kolaylaştırdığı için bu sistemlere olan ilginin giderek arttığını belirtmişlerdir. Çalışmaları içerisinde kullandıkları öneri sistemleri için Apriori algoritmasından faydalanmış ve sonuçların oldukça başarılı olduğunu ifade etmişlerdir.

Stark vd. (2019) sağlık alanında kullanılmak üzere geliştirilmiş öneri sistemlerini inceledikleri bir çalışma gerçekleştirmişlerdir. Toplamda 6 farklı veri tabanı üzerinde 13 farklı çalışmayı inceleyerek bu sistemlerin farklı algoritmalar üzerinde çalışmaları sebebiyle avantajlarının ve dezavantajlarının olduğunu belirtmişlerdir. Gelecek çalışmalar için önemli bir yönün ise grafik veri tabanlarına (graph database) bağlı sistemlere doğru olduğunu söylemişlerdir.

Suleiman vd. (2020) bayes ağlarını (Bayesian Networks) kullandıkları bir öneri sistemi çalışması gerçekleştirmişlerdir. Geliştirdikleri öneri sistemini hastanelerde yatışı gerçekleştirilen hastaların tanı ve tedavisi için kullanılan klinik kodların hastalar ile hatasız ve doğru bir şekilde eşlenebilmesi için kullanılacağını belirtmiş, performans testlerini hasta bakımı bölümündeki kodların bir kısmının rastgele çıkarılıp ardından tahmin sonuçlarının da yetkili kişiler tarafından kontrol edilerek kaçının doğru olduğunun hesaplandığı bir sistemde gerçekleştirmişlerdir. Çalışma sonucunda sistemin performansının %96 seviyesinde olduğu ve aynı zamanda %68 oranında daha az alakasız öneriler yaptığı belirtilmiştir.

Hell vd. (2020) yaptıkları çalışmada eczanelerde yapılan çapraz satış konusundaki önerilerin zorluklarından bahsetmişler ve bu ölçekte yapılan ilk çalışmaya imza attıklarını belirtmişlerdir. Müstahzarların karmaşık tıbbi altyapısının yüksek hacimli satışlar ile birleştirildiğinde öneri zorluğunun oldukça arttığına değinerek derin öğrenme

algoritmalarının özellikle bu tarz karmaşık sistemler için her geçen gün daha da önemli bir hal aldığını söylemişlerdir. Çalışmada özellikle grafik tabanlı sistemlerin performans ve sonuç anlamında son derece başarılı olduğuna değinilmiştir. PharmaSage adını verdikleri algoritma ile grafik evrimsel sinir ağıları (Graph Convolutional Neural Network) kullanılarak eczacılık alanında ürün-ürün odaklı öneri olarak yapılan ilk çalışmaya imza attıklarını dile getirmişlerdir. 100 milyonun üzerinde satış verisi ve ürün bilgilerinin birleşimi ile yapılan çalışmalar sonucunda oldukça başarılı sonuçlara ulaşıldığını belirterek daha önceki öneri sistemlerinde yer alan popüler olmayan ürünlerin önerilmemesi ya da çok az miktarda önerilmesi sorununu aştıklarını belirtmişlerdir.

3. GENEL BİLGİLER

Bu bölümde konunun daha iyi anlaşılabilmesi için öneri sistemleri ve çalışmada kullanılan yöntemler ile ilgili ayrıntılı bilgilere yer verilecektir.

3.1. Öneri Sistemleri

Öneri sistemleri kullanıcıların ilgisini çekecek servis ya da ürünleri sunarak onlara yardımcı olmayı amaçlayan sistemlerdir (Da'ı ve Salim, 2020). Daha açık bir ifade ile öneri sistemleri çok büyük veriler bulunan yapılar içerisinde kullanıcı için en anlamlı ve doğru sonucu kullanıcı ile buluşturmayı hedefler (Çilingir, 2019). İçerisinde, kullanıcının ilgi alanlarına dayalı olarak öneriler yapmayı sağlayan veri filtreleme yöntemleri barındırır.

Öneri sistemlerinin en yaygın kullanım alanı e-ticaret siteleridir ancak günümüzde kullanım alanları her geçen gün daha da artmakta olup neredeyse her sektörde kendisine yer edinmektedir. Kullanım alanlarının hızla artmasındaki en büyük neden ise hem sağlayıcılar ve hem de kullanıcılar bazında karşılıklı bir fayda sağlamasıdır (Kurt, 2019). Kullanıcılar erişim kolaylığı kazanırken, sağlayıcıların ise müşterileri dolayısıyla da kazançları artmaktadır. Oluşturulan bu karşılıklı kazanç politikası öneri sistemlerinin arkasında yatan en büyük güçtür.

Öneri sisteminin kullanım alanına bağlı olacak şekilde ürünler müzik, video, kıyafet, internet sitesi, vb. olarak karşımıza çıkabilir. Örneğin, müzik dinleme ya da video izleme platformları kendi içeriklerini kullanıcılarına izlemeleri ya da dinlemeleri için önerirken çevrimiçi alışveriş siteleri kıyafet önerimi yapmak için öneri sistemlerinden faydalanır. En büyük örnekler incelendiğinde karşımıza Amazon, Netflix, Facebook gibi örnekler çıkmaktadır.

Amazon öneri sistemleri için önde gelen kuruluşlardandır ve elektronik, kitap, kıyafet gibi kategoriler başta olmak üzere neredeyse her alanda ürünleri kullanıcılar ile buluşturmaktadır. Kullandıkları öneri sistemlerinin temelinde kullanıcılar tarafından sağlanan puanlama, satın alma, arama ve görüntüleme verileri yer almaktadır. Puanlama

amazon tarafından 5 yıldızlı bir ölçek üzerinden değerlendirilir. Sistem en düşük puan 1 yıldız ve en yüksek puan 5 yıldız olacak şekilde oluşturulmuştur. Buna ek olarak her kullanıcı için satın alma, arama ve görüntüleme verileri kullanıcı hesapları ile bağlı olacak şekilde toplanır. Toplanan tüm bu veriler ışığında kullanıcı uygulamaya yeniden giriş yaptığında kullanıcının ilgisini çekebilecek önerilerin karşısına çıkması sağlanır (Aggarwal, 2016). Kullanıcıların puanlamasına dayanan ve Amazon tarafından değerlendirilen verilere örnek bir gösterime Şekil 3.1’de yer verilmiştir.



Şekil 3.1. Amazon puanlama sistemi için örnek gösterim

Bu örnek incelendiğinde üç farklı kullanıcının üç farklı ürün için yaptıkları değerlendirmeler gösterilmektedir. Kullanıcı 1 ve kullanıcı 3’ün puanlamalarına bakıldığında ürün 1 ve 2 için olumlu ve ürün 2 için olumsuz puanlama yaptıkları görülmektedir. Kullanıcı 2 ise diğer kullanıcıların aksine ürün 1 için olumsuz bir puanlama yaparken ürün 2 için olumlu bir puanlama yapmıştır, bunun yanında ürün 3 için net bir karar verememiştir. Tüm bu puanlamalar sonucunda kullanıcı 1 ve kullanıcı 2’nin benzer puanlamalar yaptığı ve benzer kullanıcılar olarak gruplanabileceği kullanıcı 3’ün ise onlardan farklı olarak puanlamalar yaparak farklı bir grupta dahil edilebileceği ortaya çıkmaktadır. Kullanıcı 1 ve 3 için bir diğerinin yaptığı puanlama baz alınarak öneri yapılmaktadır. Örneğin yeni eklenen bir ürün için kullanıcı 1 olumlu değerlendirme

yaptığında sistem bu ürünü kullanıcı 3'ün de beğenebileceğini hesaplayarak yeni eklenen ürünü kullanıcı 3'e de önerecektir.

Netflix öneri sistemlerinden faydalanan bir başka önemli platformdur ve kullanıcılarına abonelik ile film ve dizi yayın akışı sağlamaktadır. Netflix de Amazon ile benzer şekilde öneri sisteminin temelinde kullanıcıların yaptığı değerlendirmeleri ve platform içindeki davranışlarını kullanır. Kullanıcıların içerikleri beğenip beğenmediği şeklinde puanladığı bir değerlendirme yapısı kullanır. Buradaki değerlendirme 5 puan en yüksek 1 puan en düşük olmak üzere bir ölçek kullanılır. Ayrıca kullanıcıların aradıkları içerikleri ve içeriklerin tamamını izleyip izlemediği bilgisi toplanarak öneri algoritmasına dahil edilir (Aggarwal, 2016). Puanlamaların ardından kullanıcılar ve beğendikleri video içerikleri arasındaki ilişki Şekil 3.2'de gösterilmektedir.

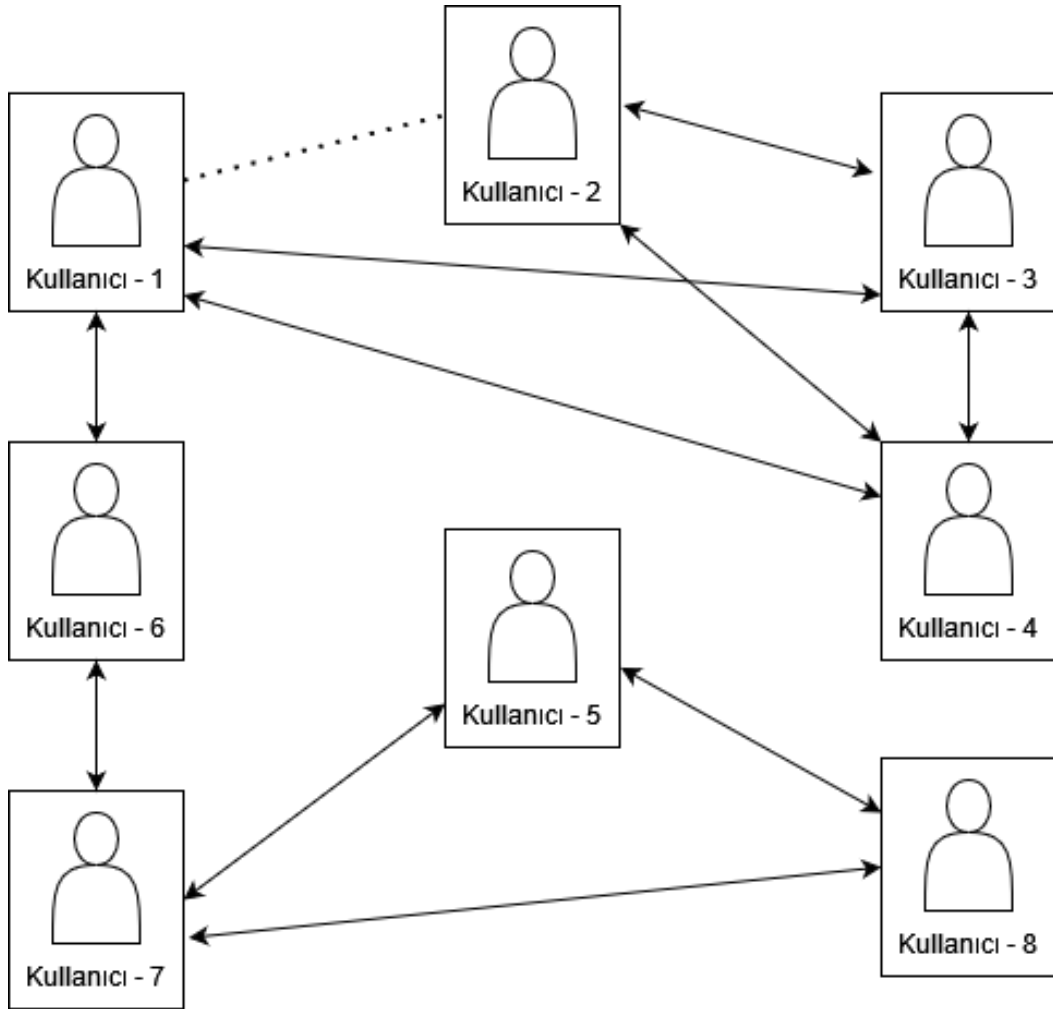


Şekil 3.2. Netflix kullanıcı ve ürün ilişkileri için örnek görselleştirme

Örnek üzerinde yer alan kullanıcı ve puanladıkları video içerikleri incelendiğinde kullanıcı 1 ve 3'ün yaptıkları puanlamalar sonucunda benzer kullanıcılar olduğu sınıflandırılabilir. Kullanıcı 2 diğerlerinden daha farklı zevklere sahip bir kullanıcı olarak karşımıza çıkmaktadır. Benzer kullanıcı olarak sınıflandırılabilen kullanıcı 1 ve 3 göz önüne alındığında kullanıcı 1'in beğendiği ancak kullanıcı 3 tarafından henüz değerlendirilmemiş video 3 ve 4 içerikleri kullanıcı 3'e önerilebilir.

Başta Facebook olmak üzere sosyal ağlar kullanıcılara genellikle olası arkadaşlıkları önererek site içerisinde yer alan bağlantıları arttırmayı amaçlamaktadır. Bu tip öneriler ürün öneren sistemler ile kıyaslandığında oldukça farklı bir amaca ulaşmayı hedeflemektedir.

Ürün öneri sistemlerinde kullanıcılara ilgisini çekebilecekleri ürünler önerilerek satışların artırılması hedeflenirken arkadaş öneri sistemlerinde kullanıcılara ilgilerini çekebilecek ve çevrelerini genişletebilecek farklı bağlantılar önerilerek ağ üzerindeki deneyimini artırarak ağdan kopmasını engellemek ve daha fazla vakit geçirmesini sağlamak amaçlanmaktadır. Böylece bir sistem yapılan satışlar tarafından gelirini arttırmayı hedeflerken olurken diğer sistem ise kullanıcıların ağda kalması sonucu reklam gelirlerini arttırmayı hedefler. Kullanıcılar arasındaki bağlantılar tahmin edilmeye çalışırken kullanıcıların profil bilgileri ve içerikler ile olan etkileşimlerinden yararlanılır (Aggarwal, 2016). Kullanıcı bağlantılarını gösteren örnek bir ilişki grafiği Şekil 3.3'te yer almaktadır.



Şekil 3.3. Sosyal ağlar için örnek kullanıcı bağlantı gösterimi

Sosyal ağ bağlantı örneğinde her bir kullanıcının diğer kullanıcılar ile bağlantıda olup olmadığı bilgisi gösterilmektedir. Grafik üzerinde yer alan her bir bağlantı incelendiğinde

kullanıcı 1 ve kullanıcı 2'nin iki ortak bağlantısı bulunmasına rağmen bağlantı kurmadıkları görülmektedir. Sistem tarafından bu ilişki göz önünde bulundurularak iki kullanıcı arasında bir bağlantı olabileceği tahmin edilerek kullanıcı 1 ve kullanıcı 2'ye birbirleri bağlantı önerisi olarak sunulmaktadır.

Eczacılık tarafına bakıldığında Hell vd. (2020) tarafından sunulan ve PharmaSage adı verilen bir öneri sistemi göze çarpmaktadır. Bu sistem müstahzarların ürün-ürün ilişkilerini ve satış bilgilerini işleyerek eğitilen bir derin öğrenme modeli temeline dayanmaktadır. Ürün-ürün içerikler özellikle müstahzarların etken madde, yan etki ve etkileşim bilgilerini içerir. Ayrıca sistem popüler ürünlerin yaygın şekilde önerilerek diğer ürünlerin önüne geçmesini önleyecek bir yapıda inşa edilmiştir.

Öneri sistemleri genellikle yaptıkları öneri türüne göre gruplandırılırlar. Bu gruplar içerik tabanlı filtreleme, iş birliği tabanlı filtreleme ve hibrit sistemlerdir (Şekil 3.4).




Şekil 3.4. Öneri sistemleri Yöntemleri

3.1.1. İçerik tabanlı filtreleme (Content based filtering)

İçerik tabanlı filtreleme tekniği kullanıcının daha önce tercih ettiği ürünlerden yola çıkar ve bu ürünlerin diğer ürünlerle olan benzerliklerini inceleyerek önerilerde bulunur (Kurt, 2019). Bu yaklaşım Rocca'nın (2019) belirttiği gibi kullanıcı bir ürünü beğendiye benzer diğer ürünleri de beğeneceği fikrini savunur ve kullanıcı-kullanıcı etkileşimi kesinlikle söz konusu değildir. İçerik tabanlı filtreleme yapısının ayrıntısı Şekil 3.5'te verilmiştir. Ürün odaklı çalışma şekli nedeniyle yeni eklenen ve daha önce etkileşime girmemiş ürünlerin önerilmesinde iş birliğine dayalı filtreleme yöntemlerinin aksine başarılı sonuçlar ortaya çıkartır (Da'u ve Salim, 2020).

Bu metodu kullanan öneri sistemleri ürün-kullanıcı ilişkilerinden yola çıkarak çalışmaktadır. Bu nedenle ürünlerin belirli özellikleri ve açıklamaları kullanılarak sistem içerisinde yer alan diğer ürünler ile karşılaştırılır ve kullanıcının daha önce ilgilendiği ya da puanladığı ürünlerden yola çıkarak kullanıcıya yapılacak öneri işlemi tamamlanır (Narke ve Nasreen, 2020). Örneğin, kullanıcı bilim kurgu alanında belirli bir yönetmenin filmlerini izlediğinde bu yönetmenin bilim kurgu üzerine çektiği diğer filmler bu kullanıcıya ilk sırada önerilecektir. Bu önerileri yönetmenin çektiği diğer alanlardaki filmler ve bilim kurgu alanında farklı yönetmenler tarafından çekilmiş filmler takip edecektir.

İçerik tabanlı yöntemler tercih edildiğinde karşılaşılabilecek en temel sorun kullanıcılara o zamana kadar incelenmiş ve ortaya çıkmış kullanıcı alışkanlıkları dışında bir önerinin yapılamamasıdır. Ayrıca başarılı önerilerin yapılabilmesi için kullanıcının ürünler ile yeterli etkileşime girmiş olması gerekmektedir. Bu yöntemi kullanan sağlayıcıların dikkat etmesi gereken en önemli şey ise sistem içerisinde yer alan ürünlerin bilgilerinin tam ve doğru şekilde girilmesinin gerekliliğidir. Bu bilgilerde yer alacak hatalar kullanıcıların doğru öneriler ile buluşmasını engelleyecektir.

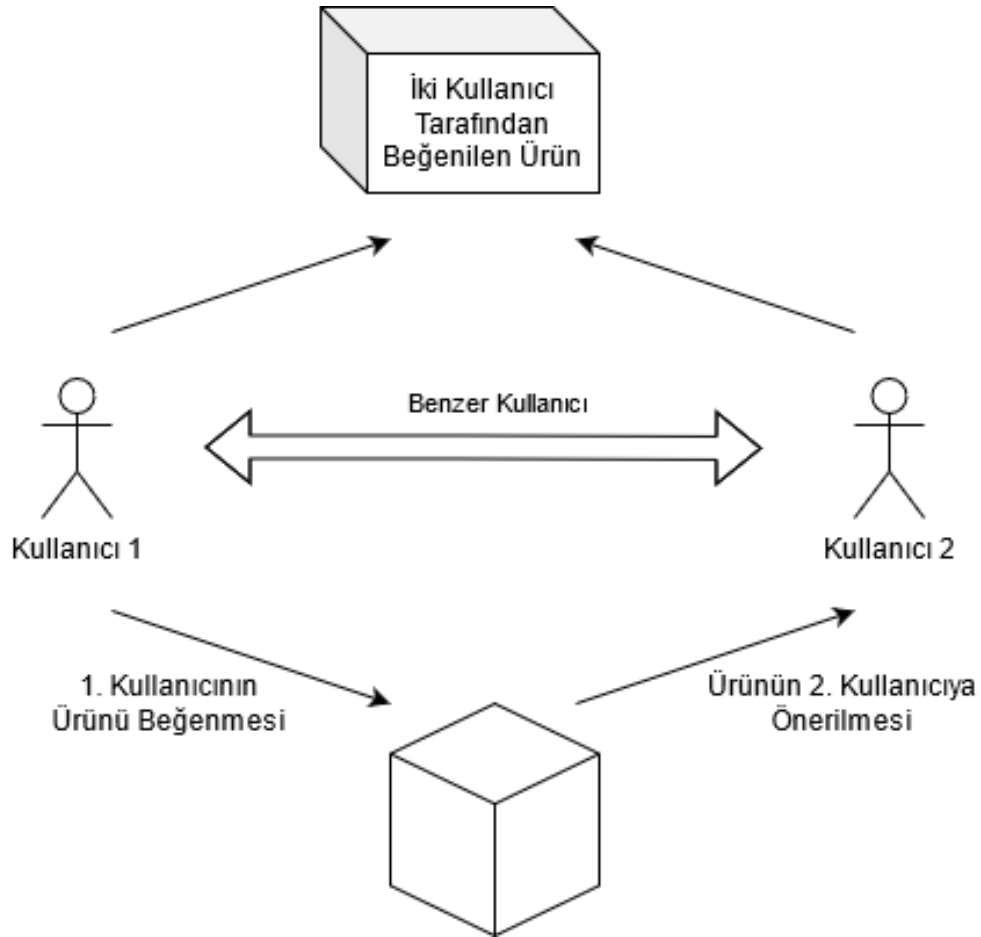


Şekil 3.5. İçerik tabanlı filtreleme yapısı

İçerik tabanlı filtreleme için görselleştirilmiş örnek yapı incelendiğinde sistem içerisinde yer alan ürün 1 ve ürün 2'nin örnek ürünler olduğu görülmektedir. Kullanıcı ürün 1'i beğendiğinde sistem tarafından kullanıcının benzer içeriğe sahip bir ürün olan ürün 2 ile de ilgilenebileceği göz önünde bulundurulur ve bu ürün kullanıcıya öneri olarak sunulur.

3.1.2. İş birliği tabanlı filtreleme (Collaborative filtering)

İş birliği tabanlı filtreleme tekniği kullanıcı özelliklerinden ve tercihlerinden yola çıkar ve bunları benzer özellikteki diğer kullanıcıların özellik ve tercihleri ile karşılaştırarak önerilerde bulunur (Çano ve Morisio, 2017). Bu yöntemde, geçmişte yapılan tercihlerin gelecekte de geçerli olacağı yani benzer seçimleri yapan kullanıcıların gelecekte de benzer seçimleri gerçekleştireceği varsayılır (Çilingir, 2019). Örneğin, aynı gömleği alan iki kullanıcıdan birincisi bir ayakkabı aldığında ikinci kullanıcının da bu ayakkabıyı alabileceği varsayılarak ikinci kullanıcıya bu ürün önerilir. İş birliği tabanlı filtreleme yönteminin ayrıntısı Şekil 3.6’da verilmiştir.



Şekil 3.6. İş birliği tabanlı filtreleme yapısı

İş birliği tabanlı filtreleme için örnek yapıya bakıldığında kullanıcı 1 ve 2’nin benzer profillere sahip kullanıcılar olduğu ve benzer ürünler satın aldıkları görülmektedir. Kullanıcı

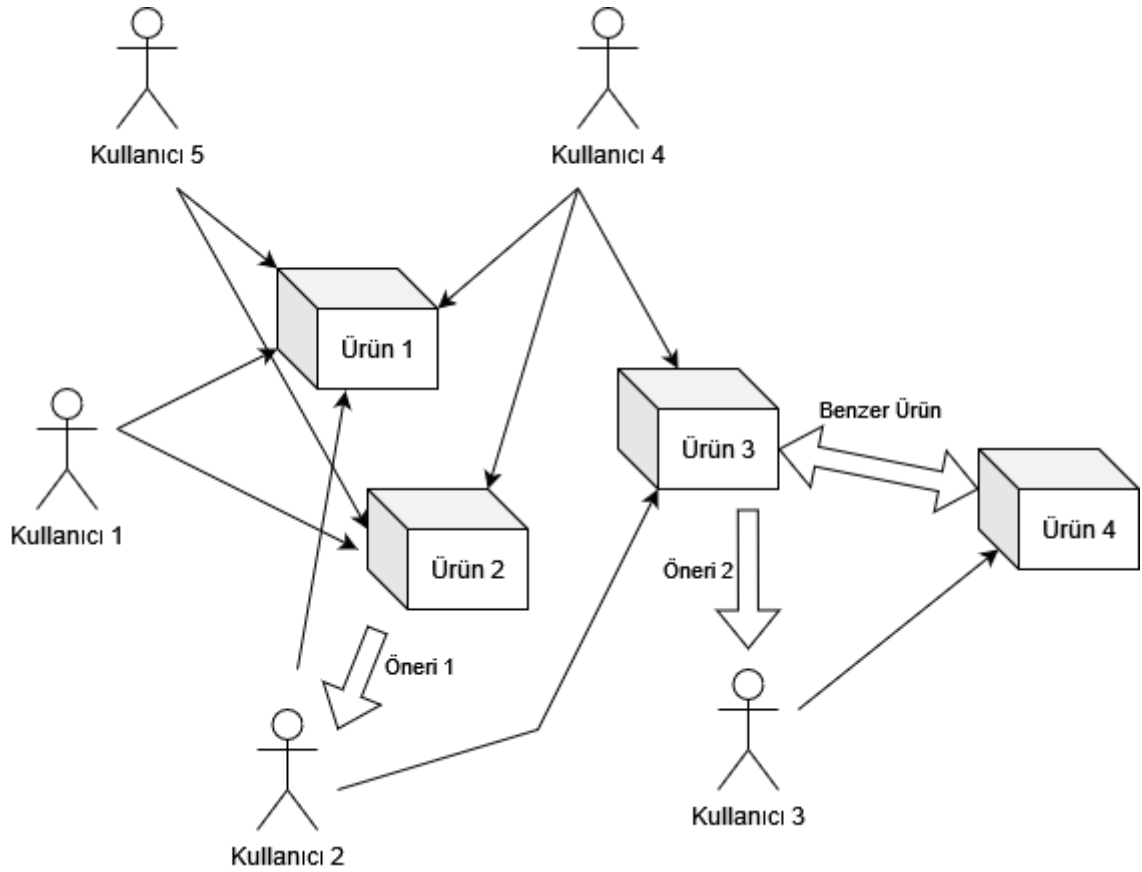
1 yeni bir ürün beğendiğinde benzer profile sahip kullanıcı 2'nin de bu ürünü beğenebileceği sistem tarafından değerlendirilerek geçerli ürün kullanıcı 2'ye öneri olarak sunulur.

Da'u ve Salim'in (2020) belirttiği gibi tesadüfi önerileri yapabilecek yeteneğe sahip olması nedeniyle, içerik tabanlı filtreleme teknikleri ile karşılaştırıldığında çok daha fazla tercih edilir. Ancak soğuk başlangıç olarak adlandırılan ve sisteme yeni eklenen ürün ve kullanıcılar hakkında yeterli bilgi bulunmamasından dolayı başarılı eşleşme yapılamaması anlamına gelen probleme yeni eklenen kullanıcılar ve ürünler üzerinde sıkça karşılaşılır. Bu tarz durumlarda yeni eklenmiş bir ürün henüz yeterli sayıda kullanıcı ile etkileşime girmedeği için ya da sisteme dahil olan yeni kullanıcı özellikleri ya da etkileşimleri yardımı ile henüz bir kullanıcı grubuna dahil olmadığı için başarılı ve tutarlı öneri sonuçları üretilemez. Ayrıca sistemin performansı sistem içerisinde yer alan değerlendirme miktarına bağlı olduğu için değerlendirme sayısı düşük miktardaki veriler ile çalışıldığında öneri sisteminden beklenen verim elde edilemeyebilir ve bu problem veri seyrekliği olarak adlandırılmaktadır. Bir başka deyişle sistem içerisinde yer alan kullanıcı ve ürün sayısının miktarının aksine asıl önemli olan sistem içerisinde yer alan bu kullanıcı ve ürünler arasında oluşan etkileşimlerin sayısıdır. Bu etkileşim ne kadar yüksek olursa sistemin daha başarılı önerilerde bulunma ihtimali de bir o kadar yükselmiş olur. Karşılaşılabilecek bir başka problem ise etkileşim sayısı uygun olsa da kullanıcı profilinin herhangi bir kullanıcı grubu ile eşlenememesidir. Bu duruma gri koyun ismi verilir ve bu tarz kullanıcıların başarılı önerilere ulaşamaması da çözülmesi gereken bir problem olarak iş birliği tabanlı sistemlerin karşısına çıkmaktadır.

3.1.3. Hibrit sistemler (Hybrid systems)

Hibrit sistemler içerik tabanlı ve iş birliği tabanlı filtreleme yöntemlerinin zayıflıklarını ortadan kaldırmayı ve güçlü yönlerinden yararlanmayı hedefleyerek bu iki tekniği tek bir öneri sistemi altında birleştirmeyi amaçlar (Danilova ve Ponomarev, 2017). Hibrit sistemler iş birliği ve içerik tabanlı sistemler ile karşılaştırıldığında çok daha başarılı ve etkili sonuçlara imza atarlar ve bu başarılı sonuçların en büyük sebebi bir algoritmanın dezavantajının başka bir algoritma ile ortadan kaldırılmış olmasıdır (Patel vd., 2017). Son dönemde hibrit sistemlerinde en çok kullanılan yaklaşım, iş birliği tabanlı sistemlerin en büyük sorunu olan soğuk başlangıç ve veri seyrekliği problemlerinden arındırabilmek için

diğer öneri sistemleri ile desteklenmesidir (Lu vd., 2015). Örneğin, iş birliği tabanlı filtreleme yönteminde yeni eklenen bir ürün hiç puanlanmadığı için önerilememe sorunu yaşanırken içerik tabanlı filtreleme yönteminde kullanıcıya o zamana kadarki ilgi alanları dışında bir içerik önerilememe sorunu yer alır. Yaşanan problemlerin üstesinden gelmek için ise bu iki yöntem birlikte kullanılarak bir hibrit sistem oluşturulmaktadır. İş birliği tabanlı ve içerik tabanlı filtreleme yöntemlerinin bir arada kullanılması ile oluşan bir hibrit yönteminin ayrıntısı Şekil 3.7’de verilmiştir ve şekil üzerinde yer alan öneri 1 iş birliği tabanlı filtreleme yardımıyla yapılmışken öneri 2’nin oluşmasında ise içerik tabanlı filtreleme rol oynamaktadır.



Şekil 3.7. Hibrit bir öneri sistemi yapısı

Örnek hibrit öneri sistemi yapısına bakıldığında sistem içerisinde yer alan ürünler, kullanıcılar ve kullanıcı-ürün etkileşimleri net şekilde görülmektedir. Yapı incelendiğinde sisteme yeni dahil olmuş ürün 4 için yalnızca bir kullanıcı etkileşimi bulunmaktadır. Ürün 4 ile etkileşimi bulunan kullanıcı 3 ise yalnızca bu ürün ile ilgilendiği için kullanıcıya diğer

kullanıcı hareketlerinden yararlanılarak öneri sunmak mümkün değildir. Bu nedenle hibrit sistem içerisinde yer alan içerik tabanlı filtreleme özellikleri devreye girerek ürün 4 ile benzer ürün olan ürün 3 kullanıcıya önerilmiştir. Yine aynı sistem içerisinde yer alan ürün 1, 2 ve 3 arasında bir benzerlik ilişkisi bulunmamaktadır. Bu nedenle sistemin bu noktasında içerik tabanlı filtreleme özelliklerinden yararlanılamayacağı için iş birliği tabanlı filtreleme özellikleri kullanılarak kullanıcı 2'ye benzer profile sahip ve benzer alımlar gerçekleştirmiş kullanıcı 1, 4 ve 5 verileri yardımıyla ürün 2 kullanıcı 2'ye önerilmiştir.

Günümüzde özellikle web uygulamaları düşünüldüğünde kullanıcılar, ürünler ve etkileşimleri hakkında çok büyük veri kaynaklarına ulaşabilmektedir bu bilgiler ışığında puanlamalar, metinsel incelemeler, ürün görüntüleri ve ürün bilgileri bir arada kullanılarak oluşturulan hibrit sistemler hakkındaki araştırmalar gün geçtikçe artmakta ve ilgi noktası haline gelmektedir. Bununla birlikte farklı kullanıcı-ürün etkileşimleri için birçok farklı model de önerilmektedir. Özellikle önerilerin doğruluğunu arttırmak için kullanıcı-ürün grafik modellerini kullanan sistemler üzerinde gerçekleştirilen çalışmalar dikkat çekmektedir (Kurt, 2019). Bu tarz grafik tabanlı sistemlerde sadece kullanıcı ve ürün özelliklerinden yararlanılmakla kalmayıp bunun yanında grafik temsilleri sayesinde bağlantı özelliklerinde de yararlanılarak daha başarılı sonuçlara ulaşılması hedeflenmektedir (Şamdan, 2014).

3.2. Öneri Sistemlerinin Karşılaştığı Problemler

Soğuk başlangıç, sisteme yeni katılan bir kullanıcının henüz hiçbir puanlama yapmamasından dolayı ortaya çıkmaktadır, benzer şekilde sisteme yeni eklenen bir ürün de henüz hiçbir kullanıcı tarafından puanlanmadığı için bu problem ile yüzleşecektir (Al-Ghuribi ve Noah, 2019). Bu sorun ile genellikle iş birliği tabanlı sistemlerde karşılaşılır, içerik tabanlı sistemlerde öneriler ürünlerin özelliklerine göre yapıldığı için böyle bir sorun yaşanmamaktadır (Bozkurt ve ACI, 2021).

Büyük kapsamlı uygulamalar düşünüldüğünde kullanıcı ve ürün sayıları oldukça fazladır ve kullanıcılar birçok ürünü puanlamış olsa da sistem içerisinde puanlanmamış yani henüz bilinmeyen ilişki sayısı puanlanmış yani bilinen ilişkilere oranla fazla olabilir, bu durum veri seyrekliği olarak adlandırılır ve sisteme negatif etki sağlayacaktır (Chen vd.,

2011). Özellikle iş birliği tabanlı sistemlerde seyreklik nedeniyle birbiri ile işleme dahil edilmek istenen iki kullanıcı arasında benzerliğin sıfır olması çok yüksek bir ihtimaldir ve sistemi kullanışsız yapmaktadır (Huang vd., 2004).

Özellikle büyük platformlar düşünüldüğünde binlerce hatta milyonlarca kullanıcının davranışlarının sonucunda oluşacak veriler günlük olarak terabaytlara ulaşabilir ve her ne kadar böyle büyük veriler üzerinde çalışsa da çoğu sistem kullanıcılara saniyenin altındaki sürelerde cevap vermeyi hedeflemektedir (Xin, 2015). Ölçeklenebilirlik olarak tanımlanan bu sorun tüm sistemler için çözülmesi gereken çok önemli bir problemidir.

Sistem içerisinde yer alan bazı kullanıcıların seçimleri diğer kullanıcılar ile karşılaştırıldığında herhangi bir kullanıcı grubu ile uyumsuz ve iş birliğine dayalı öneri sistemleri bu kullanıcılar için başarılı öneriler sunamazlar. Sistem içerisinde yer alan bu uyumsuz kullanıcılar gri koyun olarak adlandırılır ve çözülmesi gereken bir problem olarak karşımıza çıkarlar (Gras vd., 2016).


3.3. Yapay Sinir Ağları (Artificial Neural Network)

Yapay sinir ağları, insan beyni ya da merkezi sinir sisteminin çalışmasını taklit eden bir bilgi işleme sistemidir. Bu alandaki çalışmalar beyni oluşturan nöronların modellenerek bilgisayar sistemleri üzerinde uygulanması ile başlamıştır (Arı ve Berberler, 2017). Giriş ve çıkış katmanları arasında bir ya da daha fazla katman yer alabilir ve düğümler arasındaki bağlantılar belirli ağırlıklara sahiptir. Yapay sinir ağları girdileri ve beklenen çıktıları içeren örnekler yardımı ile eğitilir. Eğitim sırasında düğümlerin sahip olduğu ağırlıklar her adımda yeniden hesaplanarak sinir ağının karar mekanizması güncellenir. (Kaytan vd., 2020). Örnek bir yapay sinir ağı yapısı Şekil 3.8’de verilmiştir.

Bir başka açıklama ise Saavedra-Benítez vd.nin (2022) belirttiği gibi yapay sinir ağları karakterize edilen beyin anatomisinin kopyalanması yoluyla insan düşüncelerini taklit etmeye çalışan bir tür yapay zeka uygulamasıdır. Çalışma mantığı veri seti üzerinden genel bilgiyi çıkarmaya ve deneyim yoluyla öğrenmeye dayanır. Ayrıca yapay sinir ağı eğitiminde en önemli noktalardan biri veri setini oluşturan verilerin doğru şekilde işlenerek hazır hale

getirilmesidir. Buradaki amaç gerçek sistemlerin en doğru şekilde taklit edilerek gerçeğe en yakın modellerin elde edilebilmesidir.

Yapay sinir ağının yeteneği topolojisinin seçilmesi ile doğrudan ilişkilidir ve ağın mimarisi, problemi öğrenebilmek için yeterince büyük, genelleme yapabilmek için ise bir o kadar küçük olmalıdır. Uygun mimariden daha küçük bir ağ problemi öğrenemezken gereğinden daha büyük bir ağ ise aşırı öğrenim gerçekleştirerek ezberlemeye neden olur (Arı ve Berberler, 2017).



Şekil 3.8. Örnek bir yapay sinir ağı yapısı

3.3.1. Derin Öğrenme (Deep Learning)

Derin öğrenme, öznitelik çıkartma ve bu öznitelikleri öğrenme amacıyla kullanılan çok katmanlı yapay sinir ağı temeline dayanan bir teoridir (Aydemir, 2022). Bir başka deyiş

ile çok sayıda soyutlama seviyesine sahip verilerin çoklu işleme katmanları yardımı ile özelliklerinin öğrenilmesini sağlayan yapılardır (Özdemir, 2022). Günümüzde nesne tespiti, görüntü renklendirme, görüntü tamamlama, ses tanımlama ve daha birçok farklı alanda derin öğrenme tekniklerinden yararlanılmaktadır (Köse, 2022).


Derin öğrenme makine öğreniminin bir alt alanı olarak değerlendirilir ve makine öğrenimi yöntemlerinin aksine öznitelik çıkarma yöntemlerinden faydalanmaz. Öznitelik çıkarımını ön işlem uygulanmış ham veri içerisinden otomatik olarak gerçekleştirir (Özdemir, 2022). Öğrenmede kullanılan sinir ağları, her katmanda belirli sayıda nöronlar bulundurur ve bu katmanlar kendilerinden önceki katmanın çıkışını girdi olarak kabul ederek çıktısını hesaplar (Aydemir, 2022).

Derin öğrenmenin popülerliği ve kullanımı 2012 yılında gerçekleştirilen ImageNet yarışması ile artmıştır. Yarışmada birçok farklı kategoride derin öğrenme modelleri ile nesne sınıflandırma işlemleri yapılmıştır ve sonucunda bu alanda sıklıkla kullanılan evrimsel sinir ağı yapısı hayatımıza girmiştir (Köse, 2022).

3.3.2. Evrimsel Sinir Ağları (Convolutional Neural Network)

Evrimsel sinir ağları, diğer yöntemlerde manuel olarak yapılan özellik çıkartma işini otomatik olarak yapan sinir ağlarıdır. Evrimsel sinir ağları girdi olarak ham veriyi alır ve içerisinde yer alan evrim, aktivasyon, havuzlama, düzleştirme, bağlı çıktı katmanı gibi farklı katman türlerinden geçirerek çıktıyı elde eder (Özdemir, 2022). Örnek bir evrimsel sinir ağı yapısı Şekil 3.9'da verilmiştir.

Evrimsel sinir ağları, özellikle görüntü tanıma ve sınıflandırma alanında en güçlü model olarak karşımıza çıkar. Bu ağlar bir ya da daha fazla evrim katmanı içerir ve evrim işlemi sonunda genellikle havuzlama işlemi yardımı ile parametrelerin azaltılma işlemi gerçekleştirilir (Dandıl vd., 2019). Düzleştirme katmanları yardımı ile yapay sinir ağları tarafından gelen ve çıktıyı üretmekle görevli olan tam bağlantılı katman için veriler düzenlenir (Orman vd., 2021).

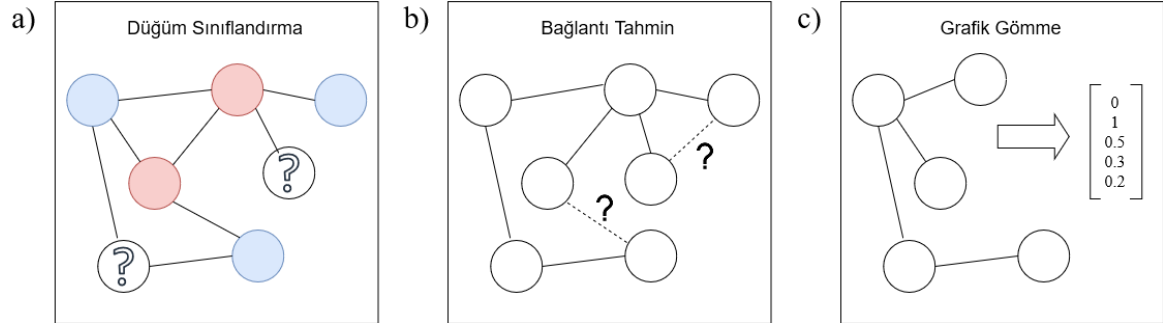


Şekil 3.9. Örnek bir evrişimsel sinir ağı yapısı

Evrişimsel sinir ağı modellerinin yapıları dolayısıyla eğitimleri oldukça fazla zaman almaktadır fakat eğitim sonrasında elde edilen sonuçlar oldukça başarılıdır. Eğitim, test süreçlerinin uzunluğu ve güçlü donanımsal gereksinimleri önemli bir dezavantaj olarak gözüktse de günümüzde teknolojinin gelişmesi sonucunda ortaya çıkan donanımların hızla güçlenmesi ve ulaşılabilirliğinin artması bu dezavantajı minimum seviyeleri indirmiştir ve gelecekte de bu dezavantajın tamamen ortadan kalkması mümkün gözükmektedir (Türkoğlu vd., 2020). Matematiksel yapıları nedeniyle karmaşıklığının çok fazla olması evrişimsel sinir ağı modelleri için kara kutuların oluşmasına neden olmuştur. Kara kutu deyimi verilen bir girdi için çıkan sonucun hangi adımlar sonrasında elde edildiğinin anlaşılamaması anlamına gelmektedir (Orman vd., 2021).

3.3.3. Grafik Evrişimsel Ağlar (Graph Convolutional Network - GCN)

Grafik evrişimsel ağlar, grafik tabanlı veriler için evrişimsel sinir ağlarının geliştirilmesi ile ortaya çıkmaktadır. Grafik evrişim işlemi sırasında aynı doğrusal dönüşümün düğüme ait tüm komşulara uygulanır ve birden fazla grafik evrişim katmanı yardımı ile düğüm temsilleri öğrenilir (Chen vd., 2017). Grafik evrişimsel ağlar temelde grafik evrişimsel sinir ağlarının (Graph Convolutional Neural Networks) daha basitleştirilmiş modelleridir (Özdemir, 2020). Daha geleneksel yaklaşımların aksine tavsiye için sadece veri kümesinin özelliklerine odaklanmakla kalmaz bunun yanında grafik temsiller sayesinde veri kümesinin bağlantı özelliklerinden de faydalanır (Şamdan, 2014). Grafik evrişimsel ağlar yarı denetimli düğüm sınıflandırması (node classification), bağlantı tahmini (link prediction) ve öneri sistemleri gibi alanlarda sıklıkla kullanılmaktadır (Chiang vd., 2019). Bu yöntemlerin örnek gösterimlerine Şekil 3.10'da yer verilmiştir.



Şekil 3.10. Grafik evrimsel ağ yapıları a) Düzüm sınıflandırma yapısı, b) Bağlantı tahmin yapısı, c) Grafik gömme yapısı

Düzüm sınıflandırması, eksik düğüm etiketlemesi bulunan grafiğin açıkta kalan düğümlerinin sınıflarını tahmin etmeyi amaçlar. Bağlantı tahmini, komşuluk matrisi (adjacency matrix) tamamlanmamış bir grafik için her düğüm çiftinin bağlı olup olmadığını tahmin etmeyi amaçlar. Grafik gömme (graph embedding), bir grafik ağında yer alan verileri bir vektör olarak eşlemeyi amaçlar ve genellikle öneri sistemleri içerisinde bu yöntemle yer verilir (Casalegno, 2021).

Öneri sistemleri temelinde bir bağlantı tahmin problemi olarak karşımıza çıkmaktadır ve buradaki bağlantılar kullanıcılar ile ürünler arasındaki etkileşimleri ifade etmektedir. Bağlantıları tahmin etmek için sistemler sistem içerisinde yer alan ürün özelliklerini ve arasında yer alan diğer bağlantıları değerlendirirler (Pujari, 2015). Günümüzde bağlantı tahmin algoritmaları tahminlerini grafik modellerinden yararlanarak gerçekleştirmektedir ve bu tip yöntemler gerçek dünyadaki problemlerin çözümü için en dikkat çeken yöntemler arasında yer almaktadır (Kurt, 2019).

Bağlantı tahmini probleminin çözümü için öneri algoritmalarında kullanıcı-ürün etkileşimleri grafiksel olarak düğüm ve linklerden oluşacak şekilde modellenir. Modelleme işlemi ardından düğümlerin özellikleri ve düğümler arasında yer alan bağlantıların yardımı ile olası diğer bağlantıların tahmin edilmesi amaçlanmaktadır. Kullanıcı-ürün grafiklerini temsil etmek amacıyla eşit sayıda kullanıcı ve ürün düğümüne sahip olan kare komşuluk matrisleri kullanılmaktadır. Bu temsillerde kullanıcı-kullanıcı, ürün-ürün ve kullanıcı-ürün olmak üzere farklı kombinasyonlarda bağlantılar yer almaktadır (Kunegis vd., 2010).

Bağlantı tahmin fonksiyonunun başarılı olabilmesi için iki düğümü bağlayan yolların sayısı arttığında ve yollar daha kısa olduğunda yüksek skor vermelidir. Kurt'un (2019) da belirttiği gibi bağlantı tahmin işlemi için kullanılan komşuluk matrisi A olmak üzere (i, j) kenar olduğunda $A_{ij} = 1$ ve kenar olmadığına $A_{ij} = 0$ şeklinde gösterilir. Yönlendirilmemiş ağlar için A genel olarak simetriktir. Özellik ayrışımı U dikey (orthogonal) matris ve Λ köşegen (diagonal) matris olmak üzere $A = U\Lambda U^T$ şeklinde gösterilebilir. Komşuluk matrisin özellik ayrışımı için kullanılan yöntem genellikle matrisin kuvvetlerinin hesaplanması şeklinde düşünülür ve bağlantı tahmin yöntemlerini ifade etmek için kullanılan bu yöntem denklem 3.1'de gösterilmiştir.

$$U^k = U\Lambda^k U^T \quad (3.1)$$

3.3.3.1. Komşuluk matrisi (Adjacency Matrix)

Komşuluk matrisi bağlantı tahmini için kullanılan ve öneri sistemleri düşünüldüğünde içerisinde kullanıcı-kullanıcı, kullanıcı-ürün ve ürün-ürün etkileşimlerinin bulunduğu matris olarak tanımlanabilir. Komşuluk matrisi en temel şekilde düşünüldüğünde $A \in R^{|v| \times |v|}$ ve $G = (V, E)$ olmak üzere denklem 3.2'de gösterildiği gibi tanımlanır.

$$A(u, i) = \begin{cases} 1, & (u, i) \in E \\ 0, & (u, i) \notin E \end{cases} \quad (3.2)$$

Komşuluk matrisi olarak tanımlanan A simetrik ve kare matristir. Bu sebeple ağırlığı bulunmayan ağlarda düğümleri bağlayan yolları elde etmek için matrisin katları hesaplanabilir. Bu sayede komşuluk matrisinin karesi alınarak iki düğüm arasındaki ortak komşuların sayısı hesaplanabilir. Bununla ilgili örnek denklem 3.3'te yer almaktadır.

$$N(u, i) = A^2(u, i) \quad (3.3)$$

Bu formül incelendiğinde çok önemli bir özelliği vardır. Komşuluk matrisinin karesinin girişi ne kadar büyük ise düğümler de birbirine o kadar yakındır. Bununla birlikte u düğümünden i düğüme yolların sayısı k uzunluğu için $A^k(u, i)$ bileşenleri şeklinde ifade edilebilir. Böylece iki düğümün yakınlığı da komşuluk matrisinin kuvvetlerinin ağırlıklı

toplamı şeklinde hesaplanabilir. Bu sonuçların birleştiği bağlantı tahmin yöntemi için örnek denklem 3.4'te yer almaktadır.

$$\exp(\mathbf{A}) = \mathbf{I} + \mathbf{A} + \frac{1}{2}\mathbf{A}^2 + \dots \quad (3.4)$$

Bu fonksiyon (Bkz. denklem 3.2) \mathbf{A} 'nın katlarının iki düğüm arasındaki tüm yolları içerdiğini kabul eder ve \mathbf{A} 'nın katlarının azalan ağırlıkları nedeni ile kısa yollar uzun yollara oranla daha öncelikli kabul edilir. \mathbf{A}_{II} ürün-ürün ve \mathbf{A}_{UU} kullanıcı-kullanıcı benzerlik matrisi, \mathbf{A}_{UI} ve \mathbf{A}_{IU} kullanıcı-ürün benzerlik matrisi olacak şekilde komşuluk matrisi denklem 3.5'te gösterilmiştir.

$$\begin{bmatrix} \mathbf{A}_{UU} & \mathbf{A}_{UI} \\ \mathbf{A}_{IU} & \mathbf{A}_{II} \end{bmatrix} \quad (3.5)$$

Ayrıca komşuluk matrisi \mathbf{A}_{IU} matrisinin eşlenik devriği (conjugate traspose) $\mathbf{A}_{IU} = -\mathbf{A}^T_{UI}$ olarak tanımlanır. Kunegis (2010) çalışmasında kullanıcı-kullanıcı ve ürün-ürün ilişkilerini yok sayarak bu matrislerin yerini sıfır matrisler ile doldurmuştur. Sıfır matrislerinin eklenmesinin ardından oluşan komşuluk matrisi denklem 3.6'da verilmiştir.

$$\mathbf{A} = \begin{bmatrix} \mathbf{0} & \mathbf{A}_{UI} \\ -\mathbf{A}^T_{UI} & \mathbf{0} \end{bmatrix} \quad (3.6)$$

Komşuluk matrisi \mathbf{A} temeline uygun olarak tercih matrisi olan \mathbf{A}_{UI} yalnızca 3 farklı değere sahip olabilir. Bu değerler j , $-j$ ve 0 olarak belirtilebilir. \mathbf{B} matrisi \mathbf{A} matrisine karşılık gelen ikili grafiğin çift bitişik matrisi olacak şekilde \mathbf{A} matrisi denklem 3.7'de gösterildiği gibi tanımlanabilir.

$$\mathbf{A} = \begin{bmatrix} \mathbf{0} & j\mathbf{B} \\ -j\mathbf{B}^T & \mathbf{0} \end{bmatrix} \quad (3.7)$$

Yönsüz ve ağırlıksız ağlarda yol sayma işlemi temel alındığında k uzunluğunda yollar için ağırlıklı yol sayma işlemi \mathbf{A}^k ile türetilebilir. Yalnızca kullanıcı ve ürünler arasında yer alan ilişkiyi değerlendirdiğimizde komşuluk matrisinin k kadar kuvveti matematiksel olarak denklem 3.8'de yer almaktadır.

$$A(u, i) = \begin{cases} \begin{bmatrix} (BB^T)^n & \mathbf{0} \\ \mathbf{0} & (B^T B)^n \end{bmatrix}, & k = 2n \\ j \times \begin{bmatrix} \mathbf{0} & (BB^T)^n B \\ -(B^T B)^n B^T & \mathbf{0} \end{bmatrix}, & k = 2n + 1 \end{cases} \quad (3.8)$$

Böylece, komşuluk matrisi A 'nın kuvvetlerinin toplamı, tek ve çift olmak üzere iki bileşene bölünebilir. Ancak yalnızca tek bileşenler son öneri için etkilidir. Bu nedenle tahminler A matrisine genel olarak denklem 3.9'da olduğu gibi uygulanır.

$$\exp(A) = \lambda A + \lambda_3 A^3 + \lambda_5 A^5 + \lambda_7 A^7 + \dots \quad (3.9)$$

Tahmin için verimli ve en kısa yolları garantilemek için $\{\lambda_1, \lambda_2, \lambda_3, \dots\}$ azalan ağırlıklı bir dizidir. Örnek olarak A 'nın matris üstelini alabiliriz (denklem 3.10).

$$\begin{aligned} e^A &= I + A + \frac{1}{2}A^2 + \frac{1}{6}A^3 + \dots \\ &= \left(I + \frac{1}{2}A^2 + \dots\right) + \left(A + \frac{1}{6}A^3 + \dots\right) \\ &= \left(I + \frac{1}{2} \begin{bmatrix} BB^T & \mathbf{0} \\ \mathbf{0} & B^T B \end{bmatrix} + \dots\right) + j \cdot \left(\begin{bmatrix} \mathbf{0} & B \\ -B^T & \mathbf{0} \end{bmatrix} + \frac{1}{6} \begin{bmatrix} \mathbf{0} & BB^T B \\ -B^T B B^T & \mathbf{0} \end{bmatrix}\right) + \dots \end{aligned} \quad (3.10)$$

Güçlerin toplamına bakıldığında çift kısımların kullanıcılar arasındaki ya da ürünler arasındaki benzerliklerin hesaplanmasında kullanılabileceği, tek kısımların ise kullanıcıların ilgisini çekebilecek ürünlerin bulunmasında kullanılabileceği görülmektedir. Bu sebeple yalnızca tek uzunluğa sahip yollar öneri yapılabilmesi için uygundur. Güç toplamı tek kısımların toplamı olacak şekilde A matrisinin hiperbolik sinüsü kullanılarak denklem 3.11'de olduğu gibi gösterilebilir.

$$\sinh(A) = A + \frac{1}{6}A^3 + \frac{1}{120}A^5 + \dots \quad (3.11)$$

3.4. Öneri Sistemleri İçin Eğitim Sonuçlarının Değerlendirilmesi

Öneri sistemleri için bir modelin geliştirilmesi ve eğitilmesi kadar önemli bir nokta da modellerin hangisinin daha başarılı sonuçlar verdiğinin incelenmesi ve anlaşılmasıdır. Yalnızca tek bir metrik ya da tek bir grafik üzerinden modelin başarısını yorumlamak oldukça yanlış bir davranıştır. Karşıtlık matrisi (confusion matrix) bir sınıflandırma probleminin tahmin değerlerini gösterir ve modelin değerlendirilmesi için önemli metrikleri barındırmaktadır (Öğündür, 2019). Şekil 3.11’de karşıtlık matrisi için bir görselleştirmeye yer verilmiştir.

		Tahmin	
		Pozitif	Negatif
Gerçek	Pozitif	DOĞRU POZİTİF	YANLIŞ NEGATİF
	Negatif	YANLIŞ POZİTİF	DOĞRU NEGATİF

Şekil 3.11. Karşıtlık matrisinin görselleştirmesi

Karşıtlık matrisi içerisinde yer alan ve gerçekte pozitif olan ve sistem tarafından da pozitif olarak tahmin edilmiş sonuçlar doğru pozitif (DP) olarak adlandırılır, eğer gerçekte pozitif olan bir sonuç sistem tarafından negatif olarak tahmin edilirse bu sonuçlar yanlış negatif (YN) olarak belirtilir. Gerçekte negatif olan ve sistem tarafından da pozitif olarak tahmin edilmiş sonuçlar yanlış pozitif (YP) olarak adlandırılır, eğer gerçekte negatif olan bir sonuç sistem tarafından pozitif olarak tahmin edilirse bu sonuçlar doğru negatif (DN) olarak belirtilir.

Doğruluk (accuracy) değeri modelin başarısını ölçmek amacı ile sıklıkla kullanılan bir yöntemdir ve doğru olarak sınıflandırılan örneklerin yüzdesi olarak tanımlanır. Doğruluğun hesaplanması için karşıtlık matrisi yardımı ile kullanılan metot denklem 3.12’de

paylaşılmıştır. Doğruluk modeli değerlendirmek için tek başına yeterli değildir ve yanıltıcı sonuçlar sunabilir. Bu nedenle en doğru değerlendirmeyi yapabilmek için farklı metriklerden yardım almamız gerekmektedir. Kesinlik (Precision) ve duyarlılık (Recall) karşıtlık matrisi yardımı ile hesaplanan ve sonuçların değerlendirilmesinde oldukça önemli rol oynayan iki metriktir (Öğündür, 2019).

$$\text{Doğruluk} = \frac{DP + DN}{DP + DN + YP + YN} \quad (3.12)$$

Doğruluğun sebep olabileceği yanıltıcı sonuçları bir örnek ile açıklamak gerekirse, örneğin ölümcül hastalığı olan ve olmayan insanların bulunduğu 100 kişilik bir grup içerisinde 91 kişinin ölümcül bir hastalığa sahip olmadığını ve 9 kişinin ise ölümcül hastalığa sahip olduğunu varsayalım. Sistem bu kişilerin 98 tanesinin ölümcül hastalığı olmadığını ve 2 tanesinin ölümcül hastalığa yakalandığını tahmin etmiş olsun (Çizelge 3.1). Bu durumda sistemin doğruluk değeri %91 olarak karşımıza çıkmaktadır (Bkz. denklem 3.12). Ancak sistem daha yakından incelendiğinde 91 adet ölümcül hastalığı bulunmayan kişi arasından 90 tanesini doğru tahmin ederek bu açıdan başarılı bir sonuç elde etse de ölümcül hastalığı bulunan 9 kişiden yalnızca 1 tanesini doğru tahmin edebilmiştir. Sistemin amacı ve beklenen sonuç düşünüldüğünde doğruluk değerinin yanıltıcı olduğu ve sistemin aslında beklenen performansı göstermediği açık bir şekilde görülmektedir.

Çizelge 3.1. Örnek bir karşıtlık matrisi

		Tahmin	
		Pozitif	Negatif
Gerçek	Pozitif	1	1
	Negatif	8	90

Kesinlik (precision) pozitif olarak tahmin edilmesi gereken değerlerden kaç tanesinin gerçekten pozitif olduğunu göstermektedir (Ay, 2020). Karşıtlık matrisi yardımı ile kesinliğin hesaplanması denklem 3.13'te verilmiştir. Bir önceki adımda doğruluk için verilen örnek (Bkz. çizelge 3.1) incelendiğinde kesinlik değeri %50 olarak karşımıza

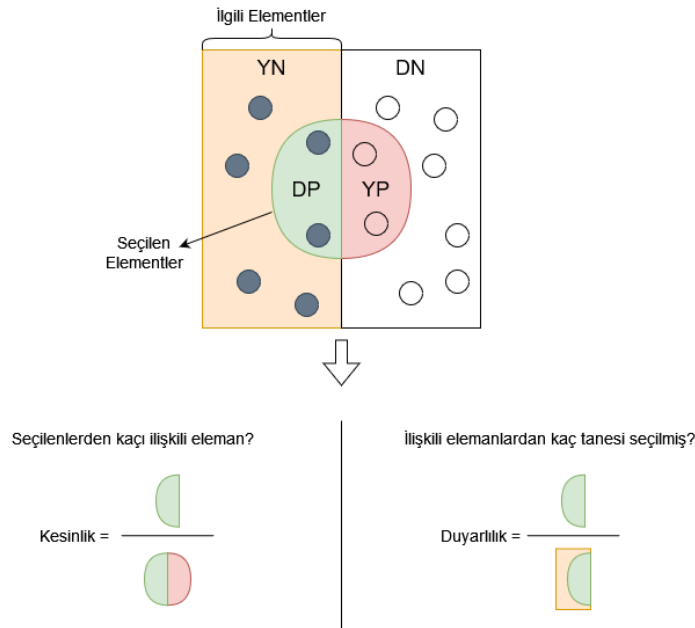
çıkmaktadır (Bkz. denklem 3.13). Bu sonuç doğruluk ile karşılaştırıldığında oldukça düşük gibi görünse de aslında beklediğimizin oldukça üzerindedir.

$$Kesinlik = \frac{DP}{DP + YP} \quad (3.13)$$

Duyarlılık (recall) pozitif olarak tahmin edilmesi gereken değerlerin kaç tanesinin gerçekten pozitif olarak tahmin ettiğimizi gösteren metriktir. Duyarlılık ve kesinlik tanım olarak birbirlerine benzeyen iki metrik olduğu için karıştırılabilmektedir (Ay, 2020). Aralarındaki farkın daha net anlaşılabilmesi için Şekil 3.12 ile görselleştirilmiştir. Duyarlılığın karşıtlık matrisi üzerinden hesaplanması denklem 3.14'te gösterilmiştir.

$$Duyarlılık = \frac{DP}{DP + YN} \quad (3.14)$$

Doğruluk ve kesinlik ile aynı örnek üzerinden incelendiğinde duyarlılık değeri %11 olarak hesaplanmaktadır ve aslında sistem için beklenen daha düşük başarıyı diğer iki metrik ile kıyaslandığında daha net bir şekilde göstermektedir. Bu durum her sistemin değerlendirilmesi için en doğru metriklerin seçilmesinin ne kadar önemli olduğunu göstermektedir.



Şekil 3.12. Kesinlik ve duyarlılık metrikleri (Anonim, 2022)

F1 skor (F1 score) değeri ise kesinlik ve duyarlılık değerlerinin harmonik ortalaması anlamına gelmektedir. Sıradan bir ortalama yerine harmonik ortalama kullanılmasının sebebi uç durumların göz ardı edilmemesi gerekliliğindendir. Eşit dağılmayan veri setleri için en doğru modelin seçilmesinde doğruluğa kıyasla F1 skor daha çok tercih edilir (Öğündür, 2019). Özellikle yüksek kesinlik ve düşük duyarlılık içeren ya da düşük kesinlik ve yüksek duyarlılık içeren modellerin değerlendirilmesinde F1 skor metriği çok önemli bir rol oynamaktadır (Ay, 2020). F1 skor değerinin kesinlik ve duyarlılık yardımı ile hesaplanması denklem 3.15'te yer almaktadır.

$$F1\ Skor = 2 \times \frac{kesinlik \times duyarlılık}{kesinlik + duyarlılık} \quad (3.15)$$

Daha önce diğer metriklerin incelemesi için kullanılan örnek üzerinden F1 skor hesaplandığında %18 sonucu ortaya çıkmaktadır. Örnek için tüm sonuçlar incelendiğinde modelin değerlendirilmesi için en tutarlı sonucun F1 skor olduğu net bir şekilde ortaya çıkmaktadır.

Açıklanan metriklerin tanımları ve verilen örnekler incelendiğinde her bir metriğin farklı beklentilere cevap verdiği net bir şekilde gözükmemektedir. Bu nedenle oluşturulan sistemler için modellerin değerlendirilmesinde gereksinimlerin önceden net bir şekilde belirlenmesi çok önemlidir. Gereksinimlerin belirlenmesinin ardından tüm bu metrikler sırasıyla incelenerek hangi metriğin sistem için daha önemli olduğu belirlenmeli bunun ardından belirlenen önem sırasına göre inceleme işlemi gerçekleştirilerek model seçimi tamamlanmalıdır. Modellerin bu şekilde seçilmesi seçilen model konusunda yapılacak hataların önüne geçecektir.

4. MATERYAL VE YÖNTEM

4.1. Kullanılan Veri Seti

Çalışmada kullanılan veri seti mobil uygulama üzerinden kullanıcıların inceledikleri müstahzar bilgilerinin anonim olarak toplanması ile oluşturulmuş olup toplamda 191578 kayıt üzerinde çalışılarak elde edilmiştir. Veri toplama işleminin ilk adımı olarak dört haftalık bir süreçte kullanıcıların görüntüledikleri müstahzar bilgileri arama yapılan tarih ve saat bilgilerini de içerecek şekilde kaydedilmiştir (Şekil 4.1).

	user	barkod	tarih
►	USER-1	8699788751697	2021-11-16 00:00:08
	USER-2	8699511010077	2021-11-16 00:01:38
	USER-3	8699788751697	2021-11-16 00:02:17
	USER-4	8712400772754	2021-11-16 00:02:57
	USER-5	5906204016579	2021-11-16 00:03:03
	USER-6	8681291340178	2021-11-16 00:03:14
	USER-7	8699525282132	2021-11-16 00:04:28
	USER-8	8699525282132	2021-11-16 00:04:28
	USER-9	8699514700050	2021-11-16 00:05:18
	USER-10	8699514700050	2021-11-16 00:05:44
	USER-11	8699564012554	2021-11-16 00:05:53
	USER-12	8699564012554	2021-11-16 00:05:53
	USER-13	8680131751648	2021-11-16 00:06:03
	USER-14	8699541273503	2021-11-16 00:06:20
	USER-15	8699717010116	2021-11-16 00:07:24
	USER-16	8690570010008	2021-11-16 00:07:29
	USER-17	8699508150311	2021-11-16 00:08:28
	USER-18	8699809098572	2021-11-16 00:08:56
	USER-19	8699570240064	2021-11-16 00:08:59
	USER-20	8680760540040	2021-11-16 00:09:09
	USER-21	8680760540040	2021-11-16 00:09:09
	USER-22	5906204016579	2021-11-16 00:09:16
	USER-23	5906204016579	2021-11-16 00:09:16
	USER-24	8699532095473	2021-11-16 00:09:39
	USER-25	8681820202021	2021-11-16 00:09:49
	USER-26	8681820202021	2021-11-16 00:09:49
	USER-27	8699548094408	2021-11-16 00:09:51

Şekil 4.1. Veri seti için toplanan örnek müstahzar arama bilgileri

Kaydedilen veriler 90, 180, 270 saniyelik zaman aralıkları halinde incelenerek kullanıcıların art arda yaptığı görüntülemelerde yer alan müstahzarlar gruplandırılmıştır

(Şekil 4.2). Zaman aralığı düşük tutulduğunda bir arada olması gereken müstahzarlar ayrı olarak değerlendirilebileceği, yüksek tutulduğunda ise bir arada olmaması gereken müstahzarların aynı grupların içerisine dahil edilerek değerlendirilebileceği göz önünde bulundurulmuş ve farklı zaman aralıklarında gruplandırma işlemleri yapılarak veri setinin kalitesinin artırılması hedeflenmiştir. Belirlenen her bir zaman aralığı için yapılan gruplandırma işlemleri ile farklı veri setleri oluşturulmuş ve ayrı ayrı incelenmiştir.

user	barkodlar	grup başlangıç tarihi	grup bitiş tarihi
USER-862	8699676950829 8699676770656	2021-11-16 15:31:21	2021-11-16 15:32:51
USER-863	8681735980052 8699630768101	2021-11-16 15:31:34	2021-11-16 15:33:04
USER-864	8680177220207 8680177220115 7391899296661 7391899856957	2021-11-16 15:32:12	2021-11-16 15:33:42
USER-865	8680177220115 7391899296661 7391899856957 7391899847344	2021-11-16 15:32:23	2021-11-16 15:33:53
USER-866	8699808794062 8699777790140 8697621790018	2021-11-16 15:32:45	2021-11-16 15:34:15
USER-867	7391899296661 7391899856957 7391899847344	2021-11-16 15:33:03	2021-11-16 15:34:33
USER-868	8699777950186 8699777950209	2021-11-16 15:33:04	2021-11-16 15:34:34
USER-869	869977790140 8697621790018	2021-11-16 15:33:09	2021-11-16 15:34:39
USER-870	8699809190047 8699546090419	2021-11-16 15:33:12	2021-11-16 15:34:42
USER-871	7391899856957 7391899847344	2021-11-16 15:33:39	2021-11-16 15:35:09
USER-872	8699809950696 8699828950103 8699828950097 8699540091023 8697927090188	2021-11-16 15:34:48	2021-11-16 15:36:18
USER-873	8699828950103 8699828950097 8699540091023 8697927090188	2021-11-16 15:35:10	2021-11-16 15:36:40
USER-874	8699828950097 8699540091023 8697927090188	2021-11-16 15:35:19	2021-11-16 15:36:49
USER-875	8699540091023 8697927090188	2021-11-16 15:35:40	2021-11-16 15:37:10
USER-876	8690570700046 8690570081077 8690570701067 8690570700039 8690570081060 869...	2021-11-16 15:36:24	2021-11-16 15:37:54
USER-877	8690570701067 8690570700046 8690570700039 8690570081060 8690570250022	2021-11-16 15:36:39	2021-11-16 15:38:09
USER-878	8690570700046 8690570700039 8690570081060 8690570701067 8690570250022	2021-11-16 15:36:50	2021-11-16 15:38:20
USER-879	8690570700039 8690570081060 8690570701067 8690570250022	2021-11-16 15:37:01	2021-11-16 15:38:31
USER-880	8697621790018 8699808794062	2021-11-16 15:37:02	2021-11-16 15:38:32
USER-881	8690570081060 8690570701067 8690570250022 8690570700039	2021-11-16 15:37:14	2021-11-16 15:38:44
USER-882	8690570701067 8690570250022 8690570700039	2021-11-16 15:37:20	2021-11-16 15:38:50
USER-883	8690570250022 8690570700039	2021-11-16 15:37:48	2021-11-16 15:39:18
USER-884	8699828190509 8699516099534 8699514092339	2021-11-16 15:38:57	2021-11-16 15:40:27
USER-885	8699516099534 8699514092339	2021-11-16 15:39:38	2021-11-16 15:41:08
USER-886	8699717280168 8699786092761	2021-11-16 15:41:21	2021-11-16 15:42:51
USER-887	8699786092761 8699786090163	2021-11-16 15:42:05	2021-11-16 15:43:35
USER-888	8681428590520 8681428570539	2021-11-16 15:43:28	2021-11-16 15:44:58

Şekil 4.2. Veri seti oluşturulurken kullanıcılara göre gruplanan örnek müstahzar bilgileri

Çizelge 4.1’de veri setleri ile ilgili ayrıntılar verilmiştir. Gruplandırma işleminin ardından veri setleri, eğitimde kullanılmak üzere %80 eğitim ve %20 test verisi olacak şekilde iki parçaya ayrılmıştır. Böylece, öneri sistemi eğitiminde kullanılacak olan ve He vd. (2020) tarafından geliştirilen LightGCN yöntemi için gerekli veri setleri elde edilmiştir. Veri seti içerisinde müstahzarlar arasında oluşmuş ikili eşleşmelerin sayısı oldukça fazladır. Bu ikili eşleşmeler nedeni ile doğrulama (validation) kümesi için ayrılacak yeterli sayıda tutarlı veri bulunmamaktadır. İkili kayıtların eksiltilmesi durumunda ise veri setinde yer alan veri sayısının yetersiz kalması söz konusu olacağından LightGCN çalışmasında da olduğu gibi veri seti oluşturulurken doğrulama kümesi ayrılmamıştır.

Çizelge 4.1. Oluşturulan veri setlerinin ayrıntıları

Veri Seti	Kullanıcı	Ürün	Etkileşim	Yoğunluk
Drug-Relation-90	12765	8415	33217	0,00031
Drug-Relation-180	19210	9793	57763	0,00031
Drug-Relation-270	22701	10282	75480	0,00032

Veri toplama işleminin son adımı olarak ise bu çalışmada yöntemin geliştirilmesinde kullanılacak olan müstahzarların eşdeğerlik (ürün-ürün) ilişkileri (Şekil 4.3) toplanarak daha önce elde edilen veri setleri içerisine dahil edilmiştir. Eklenen eşdeğer ilişkilerinde müstahzarlar arasında yer alan etkileşimler Çizelge 4.2’de yer almaktadır.

	barkod-1	barkod-2	ilişki
►	8699525282132	8699578280024	1
	8699525282132	8699525282149	1
	8699525282132	8699502280243	1
	8699525282132	8681308281005	1
	8699525282132	8699578280017	1
	8699525282132	8699828280064	1
	8699525282132	8699502280250	1
	8699525282132	8681308281012	1
	8699525282149	8699578280024	1
	8699525282149	8699502280243	1
	8699525282149	8681308281005	1
	8699525282149	8699578280017	1
	8699525282149	8699525282132	1
	8699525282149	8699828280064	1
	8699525282149	8699502280250	1
	8699525282149	8681308281012	1
	8699514700050	8690570700046	1
	8699514700050	8699844701338	1
	8699514700050	8680131751648	1
	8690570700046	8699514700050	1
	8690570700046	8699844701338	1
	8690570700046	8680131751648	1
	8680131751648	8699514700050	1
	8680131751648	8690570700046	1
	8680131751648	8699844701338	1
	8699532017802	8699033010326	1
	8699532017802	8699738010041	1

Şekil 4.3. Veri seti içerisine eklenmek için toplanan ürün-ürün bilgileri

Oluşturulan veri setlerinin kullanıcı, ürün ve kullanıcı-ürün etkileşimlerinde farklılıklar gözlenmektedir (Bkz. Çizelge 4.1). Bu farklılıkların sebebi, gruplandırma işleminin ardından ortaya çıkan sonuçlarda yer alan, bir gruba dahil olmamış ve tek müstahzar olarak oluşan kayıtların veri seti oluşumunda göz ardı edilmesidir.

Çizelge 4.2. Veri setine eklenen eşdeğer (ürün-ürün) ilişkileri

Veri Seti	Ürün Sayısı	Etkileşim Sayısı	Yoğunluk
Drug-Relation-90	8415	13408	0,00019
Drug-Relation-180	9793	16314	0,00017
Drug-Relation-270	10282	17344	0,00016

4.2. Kullanılan Metot

Bu çalışmada geliştirilen ve LightGCN+ olarak isimlendirilen yöntem temel olarak He vd. (2020) tarafından oluşturulan LightGCN öneri modeline dayanmaktadır. LightGCN'nin amacı, Wang vd. (2019) tarafından geliştirilmiş NGCF modelinde yer alan iş birliği tabanlı filtreleme üzerinde küçük etkiye sahip fakat eğitimde performansı oldukça düşüren özellik dönüşümü (feature transformation) ve doğrusal olmayan aktivasyon (nonlinear activation) gibi elementlerinin modelden çıkarılması ile daha yüksek performanslı sonuçlar elde etmektir. LightGCN+'ın amacı ise bunlara ek olarak, ürün-ürün ilişkilerinden faydalanarak daha başarılı öneri sonuçlarına ulaşan hibrit bir sistem oluşturmaktır. Bu bölümde öncelikle LightGCN yöntemi detaylı incelenecek ve ardından LightGCN+'ın tasarımı açıklanacaktır.

4.2.1. GCN

Welling ve Kipf (2017) GCN'yi yarı denetimli düğüm sınıflandırma problemleri için evrişimleri grafik yapısında tanımlanan çok katmanlı bir evrişimsel sinir ağı olarak tanıtmıştır. GCN yapısında ana fikir grafik üzerinde yer alan düğümlerin özelliklerini öğrenmek olarak tanımlanabilir. Bu özellik öğrenim işleminin gerçekleştirilmesi için evrişim işlemleri tekrarlı olacak şekilde çalışır. Bu da komşuların özelliklerinin de işleme dahil

edilmesi anlamına gelmektedir ve burada belirtilen komşu bilgilerinin toplanması olayı denklem 4.1’de gösterilmiştir.

$$e_u^{(k+1)} = AGG \left(e_u^{(k)}, \{e_i^{(k)} : i \in N_u\} \right) \quad (4.1)$$

Belirtilen AGG bir toplama fonksiyonudur (aggregation function) ve grafik evrişimin temeli olarak tanımlanabilir. Birçok çalışmada AGG olarak ağırlıklı toplayıcı ya da çift doğrusal etkileşim toplayıcı gibi yöntemler kullanılsa da en çok kullanılan yöntemler özellik dönüşümü ve doğrusal olmayan aktivasyondur (He vd., 2020).


GCN modelinde filtreleme yayılımın her bir adımında gerçekleşir. Böylece komşuluklar arasında sadece ilgili bilgiler aktarılmış olur ve GCN’nin karmaşık doğrusal olmayan özellik temelini öğrenebilmesini sağlar (Priyesh, 2019). Mesaj iletme prosedürü denklem 4.2 ve 4.3’te verilmiştir.

$$m_i^{(l)} = \frac{1}{\sqrt{d_i}} \sum_{j \in N(i)} h_j^{(l)} \frac{1}{\sqrt{d_j}} \quad (4.2)$$

$$h_i^{(l)} = \sigma(m_i^{(l)} W^l) \quad (4.3)$$

Mesaj iletme prosedürü incelendiğinde, i düğümünün derecesi d_i , $\sigma(\cdot)$ aktivasyon fonksiyonu ve l güncelleme adımıdaki lineer dönüşüm katmanının ağırlık merkezi W^l olmak üzere denklem 4.2 mesajı komşuların ağırlıklı ortalaması olarak oluşturan toplama adımına karşılık gelir. Denklem 4.3 ise güncelleme adımı olarak oluşturulan mesaja göre i düğümünün temsilini günceller (Wu, 2021).

Kurt’un (2019) açıkladığı gibi kullanıcı ve ürünleri grafik yapısında modellemek içerik tabanlı filtreleme ve iş birliği tabanlı filtreleme yöntemlerinin bir arada kullanıldığı hibrit filtreleme yöntemleri için oldukça iyi bir yoldur. Bu yapılarda işlem T bir kullanıcı-ürün etkileşim grafiği $G = (V, E)$ olarak gösterilebilir. Bu tip grafikler ikili grafik (bipartite graph) olarak da adlandırılır (Wei, 2019) ve bir örneği Şekil 4.4’te gösterilmiştir.

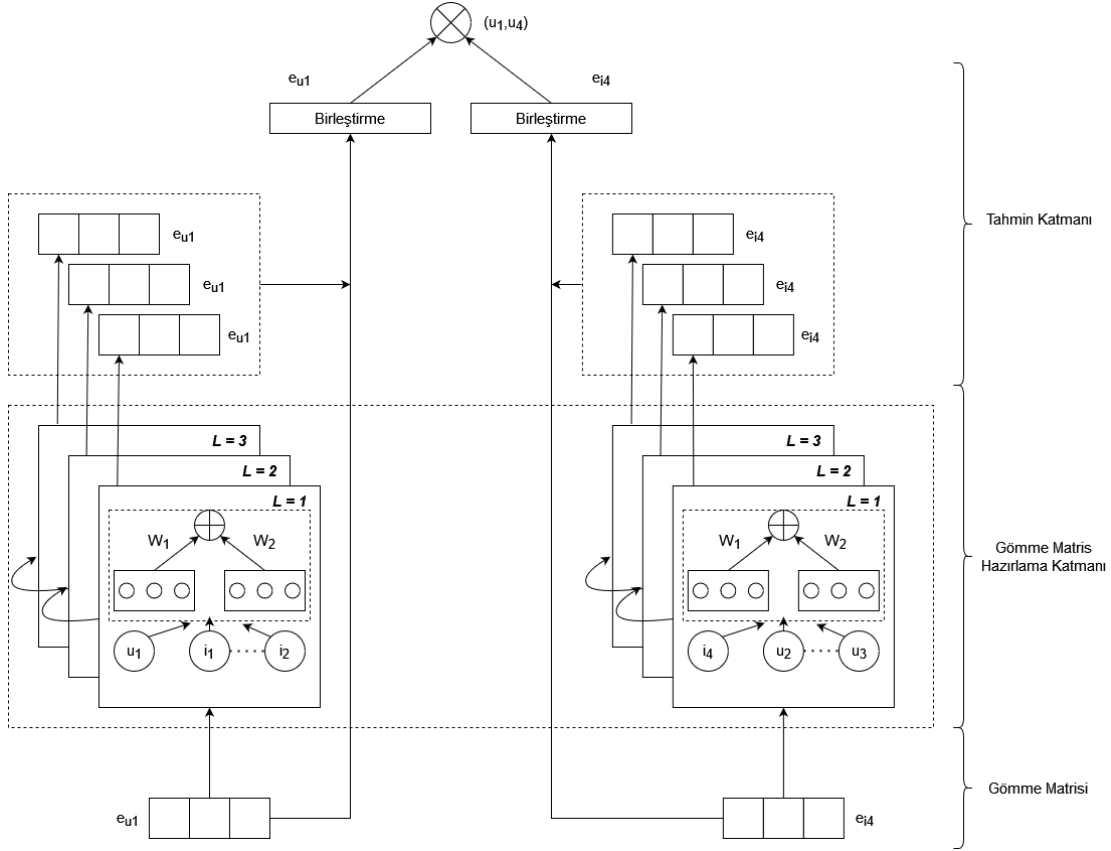


Şekil 4.4. İkili grafik örnek gösterimi

İkili grafikler tepe noktaları iki farklı bağımsız kümeye (U ve O) bölünebilen özel grafiklerdir ve her bir işlem (u, o) U 'dan O 'ya veya O 'dan U 'ya bir köşe noktası bağlar. Kullanıcı-ürün ilişki grafiklerinde kullanıcılar ve ürünler olmak üzere iki düğüm tipi bulunmaktadır ve denklem 4.4'te köşeler V , kenarlar E , kullanıcılar kümesi U ve ürünler kümesi O olacak şekilde gösterilmiştir.

$$V = U \cup O, E = \{(u, o): u \in U, u \rightarrow o \in T\} \quad (4.4)$$

Kullanıcı-ürün grafikleri komşuluk matrisi olarak da gösterilebilir. Komşuluk matrisi şeklinde gösterilen grafiklerde de iki farklı düğüm üç farklı etkileşim ile bağlantı kurabilir. Bu etkileşimler kullanıcı-ürün, ürün-ürün ve kullanıcı-kullanıcı olarak tanımlanabilir. Wang vd. (2019) tarafından sunulan NGCF yönteminde kullanıcı-kullanıcı ve ürün-ürün etkileşimleri sıfır matrisi kullanılarak doldurulmuştur. Sıfır matris kullanılmasının anlamı bu özelliklerden yararlanılmayarak sadece kullanıcı-ürün özelliklerinden faydalanılmış olmasıdır. GCN tabanlı NGCF yapısının örnek gösterimi Şekil 4.5'te verilmiştir.



Şekil 4.5. Grafik evrışimsel sinir ağı mimarisinin örnek yapısı

4.2.2. LightGCN

LightGCN, NGCF'yi temel alır ve öneri için grafik evrışimsel Ağların gerekli bileşenlerini koruyarak NGCF'nin ağır ve karmaşık yapısını hafifletmeyi amaçlar. Bu sayede LightGCN yardımıyla eğitim ve test süreleri hızlandırılırken aynı zamanda elde edilen sonuçların başarısının da korunması en büyük hedeftir. NGCF tasarımında ilk olarak kullanıcı ve ürünler birer ID ile ilişkilendirilir (He vd., 2020). $e_u^{(0)}$ kullanıcı ID ilişkisi ve $e_i^{(0)}$ ürün ID ilişkisi olarak NGCF kullanıcı-ürün ilişkisi denklem 4.5'te gösterilmiştir.

$$e_u^{(k+1)} = \sigma \left(w_1 e_u^{(k)} + \sum_{i \in N_u} \frac{1}{\sqrt{|N_u|} \sqrt{|N_i|}} \left(w_1 e_i^{(k)} + w_2 (e_i^{(k)} \odot e_u^{(k)}) \right) \right) \quad (4.5)$$

$$e_i^{(k+1)} = \sigma \left(w_1 e_i^{(k)} + \sum_{u \in N_i} \frac{1}{\sqrt{|N_i|} \sqrt{|N_u|}} \left(w_1 e_u^{(k)} + w_2 (e_u^{(k)} \odot e_i^{(k)}) \right) \right)$$

NGCF tasarımında ağırlık ve yavaşlığa sebep olan özellik dönüşümü ve doğrusal olmayan aktivasyon parçaları sistemden çıkartılarak oluşturulan LightGCN kullanıcı-ürün ilişkisi denklem 4.6’da verilmiştir.

$$\begin{aligned} e_u^{(k+1)} &= \sum_{i \in N_u} \frac{1}{\sqrt{|N_u|}\sqrt{|N_i|}} e_i^{(k)} \\ e_i^{(k+1)} &= \sum_{u \in N_i} \frac{1}{\sqrt{|N_i|}\sqrt{|N_u|}} e_u^{(k)} \end{aligned} \quad (4.6)$$

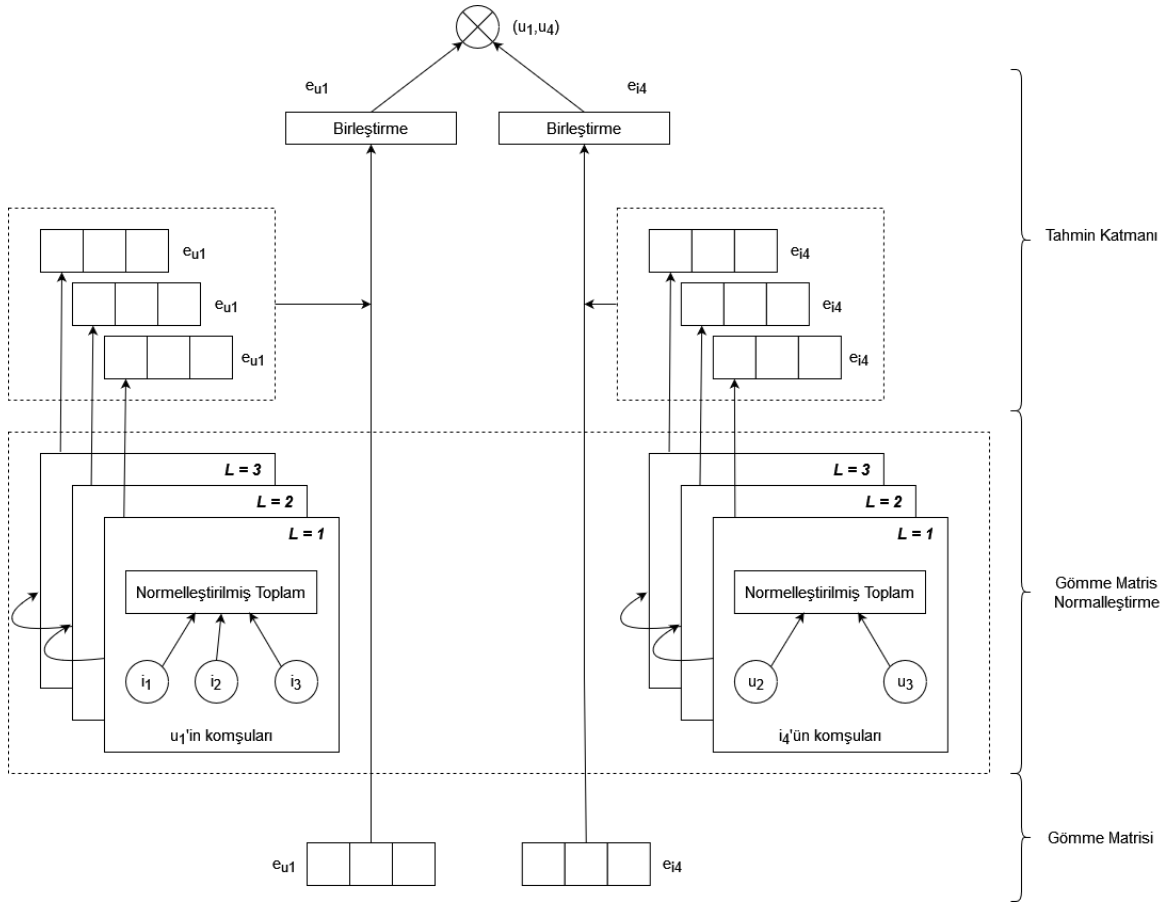
Kullanıcı-ürün etkileşim matrisi M kullanıcı sayısı ve N ürün sayısı olmak üzere $R \in \mathbb{R}^{M \times N}$ şeklinde tanımlanır. Her bir R_{ui} kullanıcı ve ürün ilişkili ise 1, değil ise 0 olarak ifade edilir. Ek olarak veri seti içerisinde bulunmayan ürün-ürün ve kullanıcı-kullanıcı ilişkileri sıfır matris ile doldurulmuştur. Bununla birlikte kullanıcı-ürün ilişkilerini gösteren komşuluk matrisi denklem 4.7’de gösterilmiştir.

$$A = \begin{pmatrix} \mathbf{0} & R \\ R^T & \mathbf{0} \end{pmatrix} \quad (4.7)$$

Komşuluk matrisi kullanılarak elde edilen, LightGCN denkleminin (Bkz. Denklem 4.5) matris eşdeğeri denklem 4.8’de verilmiştir. Bu denklem içerisinde yer alan D değeri $(M + N) \times (M + N)$ diyagonal matris olup normalleştirme işleminde kullanılmaktadır.

$$E^{(k+1)} = \left(D^{-\frac{1}{2}} A D^{-\frac{1}{2}} \right) E^{(k)} \quad (4.8)$$

LightGCN tasarımında yer alan $\frac{1}{\sqrt{|N_i|}\sqrt{|N_u|}}$ terimi (Bkz. Denklem 4.6) standart GCN yöntemindeki simetrik normalleştirme (symmetric normalization) işlemi olup matris gösterimindeki $D^{-\frac{1}{2}} A D^{-\frac{1}{2}}$ terimi (Bkz. Denklem 4.8) ile ifade edilir. LightGCN yapısının örnek gösterimi Şekil 4.6’te verilmiştir.



Şekil 4.6. Hafif grafik evrişimsel sınır ağı mimarisinin örnek yapısı

























4.2.3. LightGCN+

Günümüzde öneri sistemleri ile ilgili çalışmalar incelendiğinde içerik tabanlı ve iş birliği tabanlı sistemlerin birlikte kullanıldığı hibrit yöntemlerin ön planda olduğu ve çalışmaların bu alanda yoğunlaştığı gözükmemektedir. Bunun en önemli nedeni ise iş birliği tabanlı ve içerik tabanlı sistemlerin dezavantajlarından kurtulmak istenmesi ve bunun en etkili yolunun da bu sistemlerin bir arada kullanılmasından geçmesidir. LightGCN+ ile iş birliği tabanlı bir yöntem olan LightGCN modeli içerik tabanlı filtreleme yardımı ile genişletilerek hibrit bir sistem oluşturulmuştur.

Bu çalışmanın asıl hedefi olan eczaneler göz önüne alındığında kullanıcıların eczacılardan oluşmasından dolayı öneri sisteminin geliştirilmesinde kullanıcı-kullanıcı ilişkilerinin kullanılması mümkün değildir. Öneri sisteminin temelini oluşturan kullanıcı-ürün ilişkileri ise sistemin performansını ve başarısını belirli bir noktaya kadar

arttırabilmektedir. Tüm bu ayrıntılar düşünüldüğünde Öneri sisteminden en yüksek performansı almak için LightGCN yönteminde kullanılmayan ürün-ürün ilişkilerinin tek seçenek olduğu ve içerisinde çok önemli bir veriyi barındırdığı ortaya çıkmaktadır. LightGCN+ ile pozitif ürün-ürün ilişkileri kullanılarak sistemin performansının en üst seviyeye çıkarılması amaçlanmıştır.

LightGCN+ oluşturulurken LightGCN tasarımı kullanılmış ve öneri başarısını arttırmak için komşuluk matrisi (Bkz. Denklem 4.7) ürün-ürün ilişkileri eklenerek genişletilmiştir. Ürün-ürün etkileşimleri eklenerek oluşturulan komşuluk matrisi için temsili görseli Şekil 4.7’de verilmiştir.

	Kullanıcı 1 	Kullanıcı 2 	Kullanıcı 3 	 Ürün 1	 Ürün 2	 Ürün 3
Kullanıcı 1 						
Kullanıcı 2 						
Kullanıcı 3 						
 Ürün 1						
 Ürün 2						
 Ürün 3						

Şekil 4.7. Ürün-ürün ilişkileri içeren temsili komşuluk matrisi gösterimi

Ürün-ürün etkileşim matrisi N ürün sayısı olmak üzere $S \in \mathbb{R}^{N \times N}$ şeklinde tanımlanır. Her bir S_{ii} ürün ve ürün ilişkili ise 1, değil ise 0 olarak ifade edilir. Kullanıcı ve kullanıcı ilişkileri ise veri seti üzerinde bulunmadığı ve eczane sistemleri için uygun olmadığından sıfır matris ile doldurulur. Bununla birlikte, ürün-ürün ilişkileri eklenerek genişletilmiş komşuluk matrisi denklem 4.9’da gösterilmiştir.

$$A = \begin{pmatrix} \mathbf{0} & \mathbf{R} \\ \mathbf{R}^T & \mathbf{S} \end{pmatrix} \quad (4.9)$$

Ürün-ürün ilişkileri ile genişletilen komşuluk matrisi yardımı ile LightGCN+ yöntemi daha önce önerilen ve kendisinin temelini oluşturan NGCF ve LightGCN yöntemine oranla daha başarılı ve daha hızlı sonuçlar üretmektedir. Özellikle hedef kitlesi olan eczaneler düşünüldüğünde kullanılan sistemlerin verileri bu yöntem için oldukça uygun uygundur. Ayrıca içerdiği hibrit filtreleme yöntemi sayesinde bu alanda oldukça başarılı sonuçlara ulaşarak hem kullanıcıları olan eczacılara hem de hizmet sağladıkları hastalara pozitif etki sağlayarak zamanlarını daha rahat ve etkili bir şekilde kullanmalarına yardımcı olacaktır.

5. BULGULAR VE TARTIŞMA

Gerçekleştirilen çalışmada LightGCN ve LightGCN+ yöntemleri farklı parametreler ile oluşturulmuş olan üç farklı veri seti üzerinde çalıştırılmış ve sonuçları karşılaştırılmıştır. Eğitimin çalıştırılması için kullanılan parametreler incelendiğinde He vd. (2020) tarafından kullanılan parametrelere benzer şekilde gömme boyutu (embedding size) 64 olarak ayarlanmış öğrenme oranı (learning rate) olarak ise 0.001 kullanılmıştır. Grup boyutu (batch size) 1024 olacak şekilde tercih edilmiş ve düzenleme (regularization) değeri $1e^{-4}$ olarak kullanılmıştır. Eğitim ve test işlemleri 1’den 4’e kadar farklı katmanlar olacak şekilde uygulanmış ve 1000 devirde (epoch) işlemler gerçekleştirilmiştir. Tüm işlemler için sonuçlar kesinlik (precision) ve duyarlılık (recall) değerlerini içerecek şekilde Çizelge 5.1’de paylaşılmıştır. Ayrıca eğitim kaybı (training loss) ve test geri çağırım (testing recall) grafikleri Şekil 5.1’de yer almaktadır.

Çizelge 5.1. Farklı katmanlarda LightGCN ve LightGCN+ performans karşılaştırması

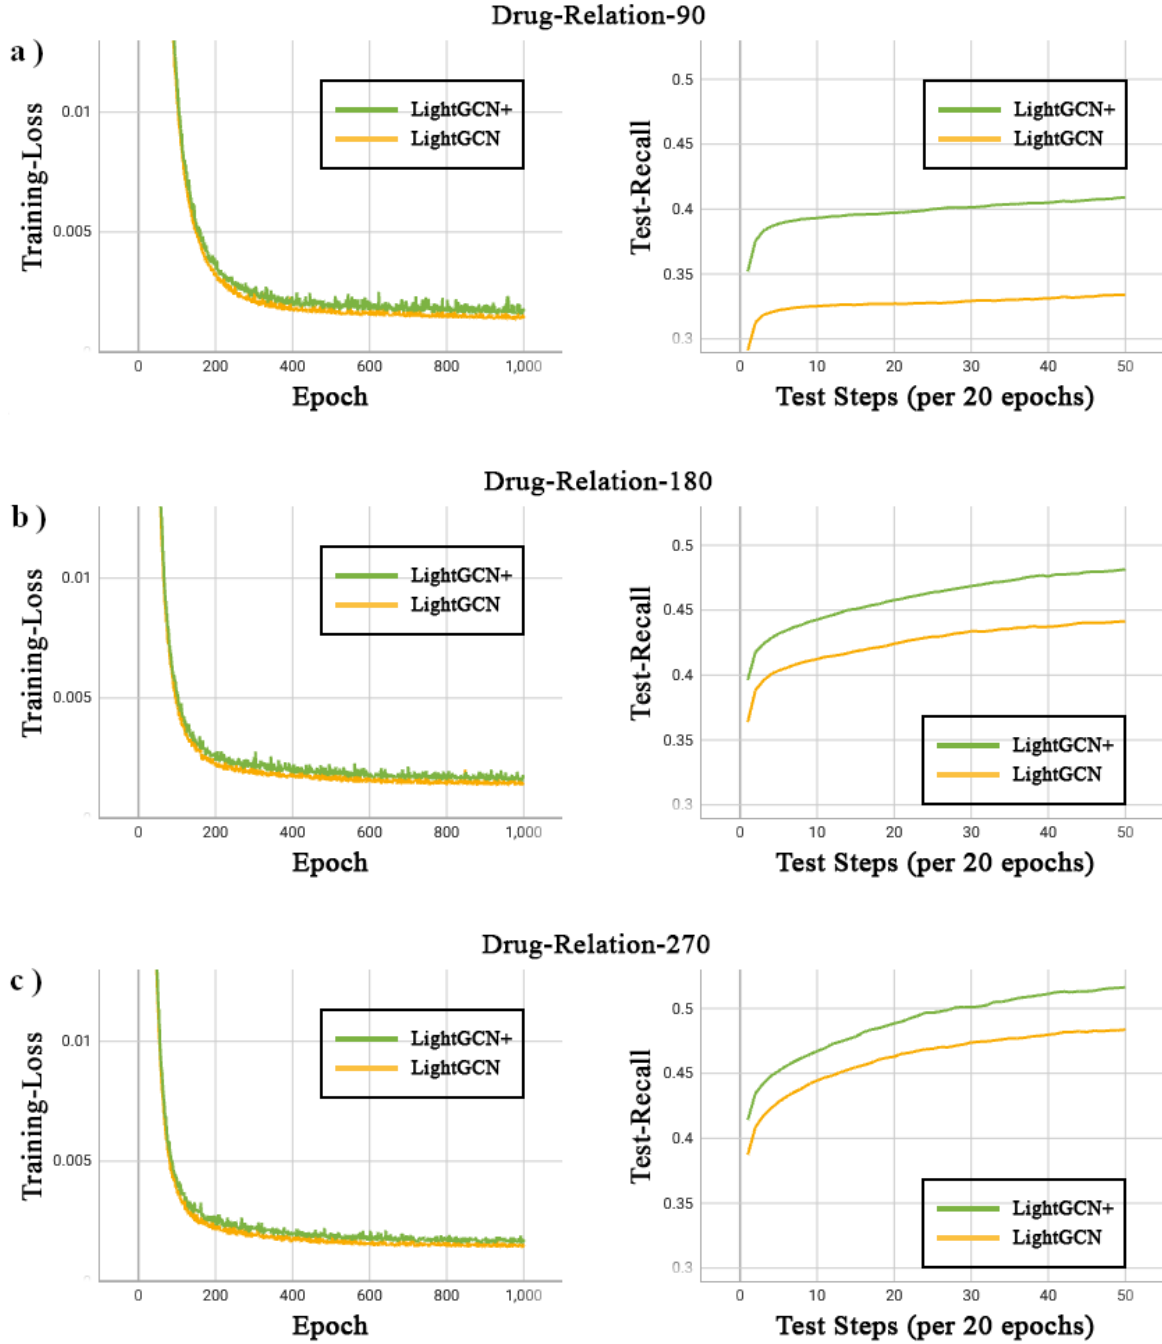
Veri Seti		Drug-Relation-90		Drug-Relation-180		Drug-Relation-270	
Katman	Yöntem	recall	precision	recall	precision	recall	precision
1 Katman	LightGCN	0,30782	0,01637	0,41921	0,02416	0,47010	0,02861
	LightGCN+	0,38206	0,02014	0,45472	0,02599	0,49525	0,02955
2 Katman	LightGCN	0,32573	0,01733	0,43871	0,02521	0,48778	0,02955
	LightGCN+	0,40234	0,02116	0,48358	0,02745	0,51962	0,03107
3 Katman	LightGCN	0,33393	0,01774	0,44126	0,02532	0,48376	0,02930
	LightGCN+	0,40890	0,02151	0,48135	0,02727	0,51632	0,03080
4 Katman	LightGCN	0,33773	0,01794	0,44472	0,02551	0,48776	0,02945
	LightGCN+	0,41310	0,02172	0,48389	0,02737	0,51347	0,03056

Performans olarak karşılaştırıldığında tüm sonuçlarda LightGCN+ ile daha başarılı sonuçlar elde edildiği görülmektedir (Bkz. Çizelge 5.1). Tüm geri çağırım sonuçları incelendiğinde kesinlik ve duyarlılık değerlerine göre ortalama %12,85 performans artışı sağlanmıştır. Eğitim işleminin gerçekleştiği farklı katman yapıları incelendiğinde en başarılı sonuçlara 4 katman üzerinde ulaşıldığı görülmektedir. Ayrıca yine eğitim ve test işlemlerinin ardından elde edilen ve paylaşılan kesinlik ve duyarlılık değerleri (Bkz. Çizelge 5.1) yardımıyla 90, 180 ve 270 saniyelik aralıklar ile oluşturulan veri setlerinin her birinin 1, 2, 3, 4 katmanda olacak şekilde F1 skorları hesaplanmış ve Çizelge 5.2’de paylaşılmıştır.

Çizelge 5.2. Farklı katmanlarda LightGCN ve LightGCN+ F1 skor karşılaştırması

Veri Seti		Drug-Relation-90	Drug-Relation-180	Drug-Relation-270
Katman	Yöntem	F1 Skor	F1 Skor	F1 Skor
1 Katman	LightGCN	0,03187	0,04569	0,05394
	LightGCN+	0,03826	0,04917	0,05577
2 Katman	LightGCN	0,03291	0,04768	0,05572
	LightGCN+	0,04021	0,05195	0,05863
3 Katman	LightGCN	0,03369	0,04789	0,05525
	LightGCN+	0,04087	0,05162	0,05813
4 Katman	LightGCN	0,03407	0,04825	0,05555
	LightGCN+	0,04127	0,05181	0,05769

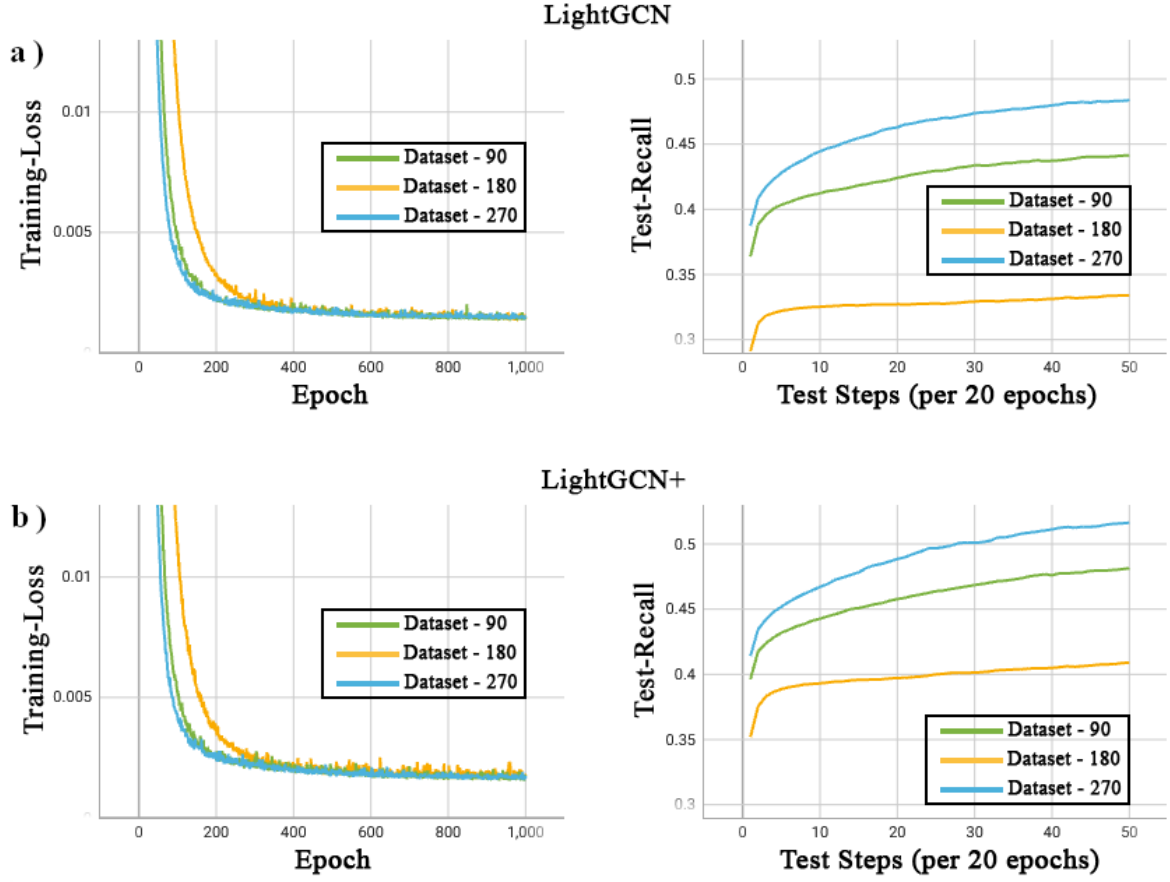
LightGCN ve LightGCN+ oluşturulan her bir veri seti için 1, 2, 3, 4 katmanlı yapılarda hesaplanan F1 skorları (Bkz. Çizelge 5.2) üzerinden karşılaştırıldığında LightGCN+ ile daha başarılı ve tutarlı sonuçların elde edildiği görülmektedir. F1 skorları için tüm sonuçlar üzerinden incelendiğinde LightGCN+ sonrasında %9,14 oranında daha başarılı sonuçların elde edildiği görülmektedir.



Şekil 5.1. Oluşturulmuş veri setleri üzerinde çalıştırılan LightGCN ve LightGCN+ modelleri için oluşan eğitim eğrileri a) Drug-Relation-90 veri seti, b) Drug-Relation-180 veri seti, c) Drug-Relation-270 veri seti

Grafikler üzerinden eğitim ve test eğrileri incelendiğinde (Bkz. Şekil 5.1) LightGCN+ modeli için eğitim kaybı değerleri daha yüksek olsa da test geri çağırım değerlerinin buna rağmen LightGCN modelinden daha yüksek sonuçlar verdiği görülmektedir. Buna ek olarak bu çalışmada oluşturulan Drug-Relation-90,

Drug-Relation-180 ve Drug-Relation-270 veri setleri üzerinde çalıştıklarında LightGCN ve LightGCN+ tekniklerinin performans karşılaştırmasına Şekil 5.2’de yer verilmiştir.



Şekil 5.2. LightGCN ve LightGCN+ modellerinin oluşturulan veri setleri üzerindeki performansları a) LightGCN, b) LightGCN+

Eğitim ve test işlemleri sonucunda LightGCN ve LightGCN+ için çalışma süreleri kontrol edildiğinde bir ve iki katmanlı yapılarda LightGCN+'ın %6'ya kadar performans artışı sağladığı gözükmemektedir. Dört katmanlı yapıda hissedilir bir performans değişimi oluşmamıştır. Üç katmanlı yapıda ise özellikle Drug-Relation-90 ve Drug-Relation-180 veri setleri için zamansal olarak performans düşüşü görülürken, Drug-Relation-270 veri setinde zamansal olarak performans artışı görülmüştür. Eğitim ve test işlemleri ile ilgili ayrıntılı zamansal bilgiler Çizelge 5.3'te paylaşılmıştır. Tüm çalışmalar incelendiğinde ortalama %0,3 performans artışı sağlanmıştır. Bu artış çok yüksek olmasa da eğitim başarısındaki artış göz önünde bulundurulduğunda yeni özellik eklemeleri sonucunda yavaşlamaya neden olmaması oldukça önemli bir sonuçtur. Ayrıca üç katmanlı yapı sonuçları hesaplama dışarısında tutulduğunda eğitim ve test işlemleri için hız artışı %2,2 seviyesine çıkmaktadır.

Çizelge 5.3. Farklı katmanlarda LightGCN ve LightGCN+ çalışma süreleri karşılaştırması

Veri Seti		Drug-Relation-90	Drug-Relation-180	Drug-Relation-270
Katman	Yöntem	Çalışma Süresi	Çalışma Süresi	Çalışma Süresi
1 Katman	LightGCN	34dk 53sn	1sa 1dk 17sn	1sa 17dk 38sn
	LightGCN+	33dk 59sn	59dk 43sn	1sa 16dk 45sn
2 Katman	LightGCN	37dk 4sn	1sa 10dk 22sn	1sa 29dk 8sn
	LightGCN+	36dk 3sn	1sa 6dk 33sn	1sa 23dk 45sn
3 Katman	LightGCN	40dk 26sn	1sa 15dk 42sn	1sa 42dk 3sn
	LightGCN+	48dk 50sn	1sa 21dk 10sn	1sa 30dk 19sn
4 Katman	LightGCN	39dk 43sn	1sa 14dk 37sn	1sa 39dk 11sn
	LightGCN+	39dk 40sn	1sa 14dk 55sn	1sa 39dk 18sn

6. SONUÇ VE ÖNERİLER

Öneri sistemleri birçok alanda kullanılmakta ve neredeyse her sektörde kendisine bir yer bulmaktadır. Bu sistemlere duyulan ihtiyacın artmasıyla birlikte yapılan çalışmaların sayısı da her geçen gün artmaktadır. Öneri sistemlerinin kullanıldığı platformların veri ve etkileşim sayıları düşünüldüğünde, daha hızlı ve daha tutarlı sonuçlara ulaşan sistemlere ihtiyaç duyulmaktadır. Performansı ve başarısı yüksek sistemlere ulaşılabilmek için ise farklı tür öneri sistemlerinin bir arada kullanılarak kendilerine özgü dezavantajları minimuma indirilmelidir. Bu tez çalışması kapsamında eczaneler için daha hızlı ve başarılı sonuçlara ulaşması hedeflenen iş birliği ve içerik tabanlı öneri sistemlerinin bir arada kullanıldığı hibrit bir yapı geliştirilmiştir. LightGCN+ adı verilen bu sistem LightGCN üzerine inşa edilmiştir. Ayrıca bu yeni sistem oluşturulurken daha doğru ve net sonuçlara ulaşabilmek için gerçek hayat verileri ve farklı parametreler kullanılarak yeni veri setleri de oluşturulmuştur.

Çalışma ardından elde edilen veriler incelendiğinde geliştirilen yöntemin daha önceki LightGCN yöntemine oranla daha başarılı sonuçlara ulaştığı görülmektedir. Bunun sebebi LightGCN+ ile sadece kullanıcı etkileşimlerine değil aynı zamanda ürün ilişkilerine de bakılarak öneri yapılmasıdır. Eklenen ürün-ürün ilişkileri sonrasında eğitim kaybı bir miktar düşse de test geri çağırım değerlerinin yani performansın arttığı görülmektedir. Ayrıca veriler arasında yeni ilişkiler eklense de eğitim ve test sürelerinin artmadığı, aksine ortalamaya bakıldığında pozitif yönde etkilendiği görülmektedir.

Çalışma sonucunda oluşturulan veri setinin en doğru ve tutarlı veri seti olmasını sağlayabilmek için verilerin ön işleme sırasında müstahzar gruplandırmaları üç farklı zaman aralığına göre yapılmıştır. Sonuçlar incelendiğinde 90, 180 ve 270 saniyelik zaman aralıkları ile oluşturulan üç veri seti arasında en iyi sonuçların Drug-Relation-270 adı verilen 270 saniyelik aralıklar ile oluşturulan veri seti üzerinden elde edildiği görülmektedir.

Sistemin daha başarılı ve tutarlı sonuçlar elde edebilmesi için kullanıcı-kullanıcı ilişkilerini göz önünde bulunduracak yeni bir öneri sistemi üzerinde çalışmalar devam ettirilebilir. Ayrıca kullanıcı-kullanıcı ve ürün-ürün ilişkileri negatif örnekler ile

desteklenerek sonuçların değerlendirilmesi daha sonraki çalışmaların hangi yönde ilerlemesi gerektiği hakkında yol gösterici olacaktır. Eczaneler için oluşturulan bu sistem düşünüldüğünde müstahzarların birbirleri ile olan etkileşimleri, negatif ürün-ürün etkileşim olarak modele dahil edilerek sonuçları nasıl etkilediği değerlendirilebilir. Bu sayede hem daha başarılı öneriler sunan bir sistem ortaya çıkartmak mümkün olabileceken hem de daha tutarlı bir veri seti oluşturularak gelecekteki çalışmalara katkıda bulunulması olası olacaktır. Benzer şekilde oluşturulan veri setinin kalitesini arttırmak amacı ile daha uzun süreli veriler toplanarak sonuçların değerlendirilmesi faydalı olacaktır. Buna ek olarak öneri sisteminin gerçek performansını ve yararını görmek amacı ile canlı bir eczane sistemine entegre edilerek test edilmesi bu alandaki çalışmaların nasıl yönlenebileceği hakkında daha ayrıntılı fikirlerin oluşturulabilmesine katkı sağlayacaktır.

KAYNAKLAR DİZİNİ

- Aggarwal, C., C., 2016, Recommender Systems, Cham: Springer International Publishing, p.498.
- Al-Ghuribi, S. M., Noah, S. A. M., 2019, Multi-Criteria Review-Based Recommender System–The State of the Art, Institute of Electrical and Electronics Engineers (IEEE) Access, 7, 169446-169468.
- Anonim, 2022, Precision and recall, https://en.wikipedia.org/wiki/Precision_and_recall, 26.07.2022
- Arı, A., Berberler, M. E., 2017, Yapay Sinir Ağları ile Tahmin ve Sınıflandırma Problemlerinin Çözümü İçin Arayüz Tasarımı, Acta Infologica, 1(2), 55-73.
- Ay, Ş., 2020, Model Performansını Değerlendirmek – Metrikler, <https://medium.com/deep-learning-turkiye/model-performans%C4%B1n%C4%B1-de%C4%9Ferlendirmek-metrikler-cb6568705b1>, erişim tarihi: 21.07.2022.
- Aydemir, C., 2022, Derin Öğrenme ve Makine Öğrenmesi ile Uydu Görüntülerinin Sınıflandırılması, Yüksek Lisans Tezi, Başkent Üniversitesi, 77 s. (yayımlanmamış)
- Bobadilla, J., Ortega, F., Hernando, A., Gutiérrez, A., 2013, Recommender Systems Survey, Knowledge-Based Systems, 46, 109-132.
- Bozkurt, M. B., ACI, Ç. İ., 2021, Öneri Algoritmalarının Film Önerme Problemi Üzerinde Karşılaştırılması: MovieLens Örneği, Bilgisayar Bilimleri ve Teknolojileri Dergisi, 1(2), 36-42.
- Casalegno, F., 2021, Graph Convolutional Networks - Deep Learning on Graphs, <https://towardsdatascience.com/graph-convolutional-networks-deep-99d7fee5706f>, erişim tarihi: 07.06.2022.
- Chen, J., Zhu, J., Song, L., 2017, Stochastic training of graph convolutional networks with variance reduction, Proceedings of the 35th International Conference on Machine Learning.
- Chen, L., Wu, L., Hong, R., Zhang, K., Wang, M., 2020, Revisiting Graph Based Collaborative Filtering: A Linear Residual Graph Convolutional Network Approach, Proceedings of the AAAI Conference on Artificial Intelligence, 34(1), 27-34.
- Chen, Y., Wu, C., Xie, M., Guo, X., 2011, Solving the Sparsity Problem in Recommender Systems Using Association Retrieval, Journal of Computers, 6(9), 1896-1902.

KAYNAKLAR DİZİNİ (devam)

- Chiang, W. L., Liu, X., Si, S., Li, Y., Bengio, S., vd., 2019, Cluster-GCN: An Efficient Algorithm for Training Deep and Large Graph Convolutional Networks, Proceedings of the 25th International Conference on Knowledge Discovery & Data Mining, p.257-266.
- Çano, E., Morisio, M., 2017, Hybrid Recommender Systems: A Systematic Literature Review, Intelligent Data Analysis, 21(6), 1487-1524.
- Çilingir, İ., 2019, Öneri Sistemleri (Recommendation Systems), <https://medium.com/@irmcilingir/%C3%B6neri-siste4mli-recommendation-systems-28a3f341c0a9>, erişim tarihi: 23.05.2022.
- Dandıl, E., Turkan, M., Boğa, M., Çevik, K. K., 2019, Daha Hızlı Bölgesel-Evrişimsel Sinir Ağları ile Sığır Yüzlerinin Tanınması, Bilecik Şeyh Edebali Üniversitesi Fen Bilimleri Dergisi, 6, 177-189.
- Da'u, A., Salim, N., 2020, Recommendation System Based on Deep Learning Methods: a Systematic Review and New Directions, Artificial Intelligence Review, 53(4), 2709-2748.
- Danilova, V., Ponomarev, A., 2017, Hybrid Recommender Systems: The Review of State-of-the-Art Research and Applications, Proceedings of the 20th Conference of FRUCT Association, p.572-578.
- Dwiputriane, D. B., Abas, Z. A., Herman, N. S., 2022, Systematic Literature Review on Enhancing Recommendation System by Eliminating Data Sparsity, Journal of Theoretical and Applied Information Technology, 100(7), 2254-2270.
- Felfernig, A., Jeran, M., Ninaus, G., Reinfrank, F., Reiterer, S., vd., 2014, Basic Approaches in Recommendation Systems, Recommendation Systems in Software Engineering, Springer, Berlin, p. 15-37.
- Gong, F., Wang, M., Wang, H., Wang, S., Liu, M., 2021, SMR: Medical Knowledge Graph Embedding for Safe Medicine Recommendation, Big Data Research, 23, 100174.
- Gras, B., Brun, A., Boyer, A., 2016, Identifying Grey Sheep Users in Collaborative Filtering: A Distribution-Based Technique, Proceedings of the 2016 Conference on User Modeling Adaptation and Personalization, p.17-26.
- Grattarola, D., 2021, Graph Neural Network Operators and Architectures, Ph.D. Dissertation, Università Della Svizzera Italiana, 249 p. (unpublished).

KAYNAKLAR DİZİNİ (devam)

- He, X., Deng, K., Wang, X., Li, Y., Zhang, Y., vd., 2020, LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation, Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval, p.639-648.
- Hell, F., Taha, Y., Hinz, G., Heibei, S., Müller, H., vd., 2020, Graph Convolutional Neural Network for a Pharmacy Cross-Selling Recommender System, Information, 11(11), 525.
- Hu, S., Lu, L., Jin, X., Jiang, Y., Zheng, H., vd., 2017, The Recommender System for a Cloud-Based Electronic Medical Record System for Regional Clinics and Health Centers in China, 2017 IEEE International Conference on Bioinformatics and Biomedicine (BIBM), p.1021-1024.
- Huang, Z., Chen, H., Zeng, D., 2004, Applying Associative Retrieval Techniques to Alleviate the Sparsity Problem in Collaborative Filtering, ACM Transactions on Information Systems (TOIS), 22(1), 116-142.
- Kaytan, M., Yeroğlu, C., Aydılek, İ. B., 2020, Yapay Sinir Ağları Eğitiminde Kullanılan Optimizasyon Yöntemlerinin İncelenmesi ve Kan Nakli Hizmet Merkezi Veri Seti Üzerinden Değerlendirilmesi, Computer Science, 5(2), 99-113.
- Köse, Ü., 2022, Kötü Amaçlı Yazılımların Derin Öğrenme Yöntemi ile Tespit Edilmesi, Yüksek Lisans Tezi, Ankara Üniversitesi, 66 s. (yayımlanmamış)
- Kunegis, J., Luca, E. W. D., Albayrak, S., 2010, The Link Prediction Problem in Bipartite Networks, International Conference on Information Processing and Management of Uncertainty in Knowledge-based Systems, p. 380-389.
- Kurt, Z., 2019, Graph Based Hybrid Recommender Systems, Ph.D. Dissertation, Anadolu University, 120 p. (unpublished).
- Lu, J., Wu, D., Mao, M., Wang, W., Zhang, G., 2015, Recommender System Application Developments: A Survey. Decision Support Systems, 74, p.12-32.
- Narke, L., Nasreen, A., 2020, A Comprehensive Review of Approaches and Challenges of a Recommendation System, International Journal of Research in Engineering, Science and Management, 3(4), 381-384.
- Orman, A., Köse, U., Yiğit, T., 2021, Açıklanabilir Evrişimsel Sinir Ağları ile Beyin Tümörü Tespiti, El-Cezeri Fen ve Mühendislik Dergisi, 8(3), 1323-1337.

KAYNAKLAR DİZİNİ (devam)

- Öğündür, G., 2019, Doğruluk (Accuracy), Kesinlik (Precision), Duyarlılık (Recall) ya da F1 Score?, <https://medium.com/@gulcanogundur/do%C4%9Fruluk-accuracy-kesinlik-precision-duyarl%C4%B1%C4%B1k-recall-ya-da-f1-score-300c925feb38>, erişim tarihi: 20.07.2022.
- Özdemir, C., 2022, Derin Öğrenme Yöntemleri ile El Bilek Grafisinden Kemik Yaşının Tahmini, Doktora Tezi, Siirt Üniversitesi, 168 s. (yayınlanmamış)
- Özdemir, F., 2020, Recommender System for Employee Attrition Prediction and Movie Suggestion, M.Sc. Thesis, Abdullah Gül University, 68 p. (unpublished).
- Park, D. H., Kim, H. K., Choi, I. Y., Kim, J. K., 2012, A Literature Review and Classification of Recommender Systems Research, Expert Systems with Applications, 39(11), 10059-10072.
- Patel, B., Desai, P., Panchal, U., 2017, Methods of Recommender System: A Review, 2017 International Conference on Innovations in Information Embedded and Communication Systems (ICIIECS), p.1-4.
- Priyesh, V., 2019, Designing Better Graph Convolutional Networks: Scaling Graph Propagation Based Neural Networks for Collective Classification, M.Sc. Thesis, Indian Institute of Technology Madras, 106 p. (unpublished).
- Pujari, M., 2015, Link Prediction in Large-Scale Complex Networks (Application to Bibliographical Networks), Ph.D. Dissertation, Université Sorbonne Paris Cité.
- Rocca, B., 2019, Introduction to recommender systems, <https://towardsdatascience.com/introduction-to-recommender-systems-6c66cf15ada>, erişim tarihi: 25.05.2022.
- Saavedra-Benítez, Y. I., García-Morales, J., Cervantes-Bobadilla, M., Hernández-Pérez, J. A., Adam-Medina, M., vd., 2022, Case Studies in Thermal Engineering, 102075.
- Shafi, A., 2022, How to Learn the Definitions of Precision and Recall (For Good), <https://towardsdatascience.com/precision-and-recall-88a3776c8007>, erişim tarihi: 20.07.2022.
- Shafiq, A., Çolak, A. B., Sindhu, T. N., Lone, S. A., Alsubie, A., vd., 2022, Comparative Study of Artificial Neural Network Versus Parametric Method in COVID-19 Data Analysis, Results in Physics, 105613.
- Shchur, O., Mumme, M., Bojchevski, A., Günnemann, S., 2019, Pitfalls of Graph Neural Network Evaluation, Relational Representation Learning Workshop.

KAYNAKLAR DİZİNİ (devam)

- Stark, B., Knahl, C., Aydin, M., Elish, K., 2019, A Literature Review on Medicine Recommender Systems, *International Journal of Advanced Computer Science and Applications*, 10(8), 6-13.
- Suleiman, M., Demirhan, H., Boyd, L., Giroso, F., Aksakalli, V., 2020, A Clinical Coding Recommender System, *Knowledge-Based Systems*, 210, 106455.
- Şamdan, E., 2014, A Graph Based Collaborative and Context Aware Recommendation System for TV Programs, M.Sc. Thesis, Middle East Technical University, 94 p. (unpublished).
- Türkoğlu, M., Hanbay, K., Sivrikaya, I. S., Hanbay, D., 2021, Derin Evrişimsel Sinir Ağı Kullanılarak Kayısı Hastalıklarının Sınıflandırılması, *Bitlis Eren Üniversitesi Fen Bilimleri Dergisi*, 9(1), 334-345.
- Tripathy, A., Yelick, K., Buluç, A., 2020, Reducing Communication in Graph Neural Network Training, *SC20: International Conference for High Performance Computing, Networking, Storage and Analysis*, p.1-14.
- Ubaid, S., Alam, M. T., Sohail, S. S., Saifi, I. K., Mufti, T., vd., 2021, The impact of Randomized Algorithm Over Recommender System, *Procedia Computer Science*, 194, 218-223.
- Xin, Y., 2015, Challenges in Recommender Systems: Scalability, Privacy, and Structured Recommendations, Ph.D. Dissertation, Massachusetts Institute of Technology, 128 p. (unpublished).
- Wang, X., He, X., Wang, M., Feng, F., Chua, T. S., 2019, Neural Graph Collaborative Filtering, *Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval*, p.165-174.
- Wei, Y., Wang, X., Nie, L., He, X., Hong, R., vd., 2019, MMGCN: Multi-Modal Graph Convolution Network for Personalized Recommendation of Micro-Video, *Proceedings of the 27th ACM International Conference on Multimedia*, p.1437-1445.
- Welling, M., Kipf, T. N., 2017, Semi-Supervised Classification with Graph Convolutional Networks, *International Conference on Learning Representations*.
- Wu, C., 2021, Graph Representation Learning: from Kernel to Neural Networks, Ph.D. Dissertation, Institut Polytechnique de Paris, 190 p. (unpublished).
- Wu, F., Souza, A., Zhang, T., Fifty, C., Yu, T., vd., 2019, Simplifying Graph Convolutional Networks, *International Conference on Machine Learning*, p. 6861-6871.
- Zhang, S., Yao, L., Sun, A., Tay, Y., 2019, Deep Learning Based Recommender System: A Survey and New Perspectives, *ACM Computing Surveys (CSUR)*, 52(1), 1-38.

KAYNAKLAR DİZİNİ (devam)

Zhang, Y., Zhang, D., Hassan, M. M., Alamri, A., Peng, L., 2015, CADRE: Cloud-assisted Drug Recommendation Service for Online Pharmacies, Mobile Networks and Applications, 20(3), 348-355.